单位代码：10293　密　级：公开

南京邮电大学

专业学位硕士论文

论文题目：基于机器学习的血糖预测模型研究与应用

学　　号　1221045501

姓　　名　鲍善军

导　　师　陈国良

专业学位类别　电子信息硕士

类　　型　全日制

专业（领域）　计算机技术

论文提交日期　2024 年 5 月

中国知网　https://www.cnki.net

Research and Application of Blood Glucose Prediction Model Based on Machine Learning

Thesis Submitted to Nanjing University of Posts and Telecommunications for the Degree of Master of Electronic Information

By

Shanjun Bao

Supervisor: Prof. Guoliang Chen

May 2024

中国知网 https://www.cnki.net

摘要

糖尿病是一种以慢性高血糖为特征表现的代谢性疾病，可能导致许多并发症，严重威胁患者的生命安全。目前的医疗水平和条件无法根治糖尿病，只有尽早发现和积极的预防才能减小糖尿病对身体的伤害以及降低相关并发症发生的可能性。随着机器学习技术的快速发展，它已成为各个领域不可或缺的一部分，医疗领域也不例外。因此，合理利用机器学习方法构建血糖值预测模型，可以实现对血糖值的精准预测。本文基于某公司动态血糖监测系统(Continues Glucose Monitoring System, CGMS)提供的血糖数据，选择机器学习中的集成学习和增量学习为理论基础，提出了基于机器学习的血糖值预测方法。本文主要做了以下三个方面的研究工作：

（1）提出了一种基于模型融合的血糖预测模型。该模型先是通过卡尔曼滤波算法和 z-score 方法对传感器数据进行预处理，再利用粒子群优化算法对 XGBoost 和 LightGBM 模型进行超参数优化。最后，以优化后的 XGBoost 和 LightGBM 模型为基学习器，结合贝叶斯回归模型作为元学习器，对传感器数据进行训练和测试，实现对血糖值的较为准确的预测。通过实验对比的结果显示，提出的血糖预测模型在预测效果上明显优于单一的基学习器，取得了 1.76%和 2.07%的预测精度提升。相较于其他回归模型和不同的组合模型，该融合模型也展现出更高的预测精度。

（2）提出了一种基于增量学习的血糖预测实时更新模型。该模型首先通过箱线图法对数据进行异常值检测，以提高数据质量。然后，采用离散小波变换和经验模态分解对传感器信号进行分解，比较两者的效果，选择性能更优的方法。最后，利用 XGBoost 和 LightGBM 两种增量学习方式对模型进行新数据的训练和测试，每当新增数据时，并不需要重新训练模型，而是在原有的知识库的基础上，仅根据新增数据所引起的变化对模型实时更新，最终实现在减少模型训练时间的同时，对新数据的血糖值进行更为准确的预测。

（3）以基于粒子群优化和模型融合的血糖预测模型和基于增量学习的血糖预测实时更新模型为基础，设计并实现了一个完整的基于机器学习的 CGM 血糖预测系统。该系统采用模块化设计，管理员可以实时观察用户信息和所佩戴的血糖仪数据的变化，也可以更加便捷地统计不同类型血糖仪的数据情况。另外，管理员能够实时观察不同模型的预测效果，这为日后的数据处理和模型的选择提供了科学依据，有助于降低血糖预测误差，提高系统的可用性和精准性。

关键词： 血糖预测， 机器学习， 模型融合， 增量学习

中国知网 https://www.cnki.net

Abstract

Diabetes mellitus is a metabolic disease characterized by chronic hyperglycemia, which may lead to many complications and seriously threaten patients' lives. The current medical level and conditions cannot cure diabetes, only early detection and active prevention can minimize the damage of diabetes to the body and reduce the possibility of related complications. With the rapid development of machine learning technology, it has become an indispensable part of various fields, and the medical field is no exception. Therefore, the reasonable use of machine learning methods to build a blood glucose value prediction model can realize the accurate prediction of blood glucose value. Based on the blood glucose data provided by a company's Continues Glucose Monitoring System(CGMS), this thesis proposes a machine learning-based blood glucose value prediction method by choosing integrated learning and incremental learning as the theoretical basis of machine learning. In this paper, the following three main aspects of research work are done:

(1) A blood glucose prediction model based on model fusion is proposed. The model first preprocesses the sensor data by Kalman filtering algorithm and z-score method, and then uses particle swarm optimization algorithm to optimize the hyperparameters of XGBoost and LightGBM models. Finally, the optimized XGBoost and LightGBM models are used as the base learner, combined with the Bayesian regression model as the meta-learner, to train and test the sensor data, and achieve a more accurate prediction of blood glucose values. The results of experimental comparisons show that the proposed blood glucose prediction model is significantly better than the single base learner in terms of prediction, achieving 1.76% and 2.07% improvement in prediction accuracy. The fusion model also exhibits higher prediction accuracy compared to other regression models and different combination models.

(2) An incremental learning based real-time update model for blood glucose prediction is proposed. The model mainly detects outliers in the data by box-and-line plot method to improve the data quality. Then, discrete wavelet transform and empirical mode decomposition are used to decompose the sensor signals, compare the effects of both, and select the method with better performance. Finally, two incremental learning methods, XGBoost and LightGBM, are used to train and test the model for new data. Whenever new data is added, the model does not need to be retrained, but rather the model is updated in real time on the basis of the original knowledge base only according to the changes induced by the new data, which ultimately achieves a more accurate glycemic value

中国知网 https://www.cnki.net

of the new data while reducing the model training time. The final result is a more accurate prediction of blood glucose values with new data while reducing the model training time.

(3) A complete machine learning-based CGM glucose prediction system was designed and implemented based on a particle swarm optimization and model fusion-based glucose prediction model and an incremental learning-based glucose prediction real-time update model. The system adopts a modularized design, which allows the administrator to observe the changes of user information and the data of the blood glucose meters worn in real time, and also to count the data of different types of blood glucose meters more conveniently. In addition, the administrator can observe the prediction effect of different models in real time, which provides a scientific basis for future data processing and model selection, helping to reduce the glucose prediction error and improve the usability and accuracy of the system.

Key words: Glucose Prediction, Machine Learning, Model Fusion, Incremental Learning

中国知网 https://www.cnki.net

目 录

第一章 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究现状.....2
1.2.1 基于生理模型的血糖值预测.....2
1.2.2 基于数据驱动的血糖值预测.....3
1.3 本文主要内容和结构安排.....4
1.3.1 本文研究主要内容.....4
1.3.2 本文结构安排.....4
第二章 相关背景知识介绍.....6
2.1 粒子群优化算法.....6
2.1.1 基本原理.....6
2.1.2 算法伪代码.....6
2.2 集成学习算法.....7
2.2.1 XGBoost.....7
2.2.2 LightGBM.....9
2.2.3 stacking 模型框架.....9
2.3 信号分解算法.....10
2.3.1 离散小波变换.....10
2.3.2 经验模态分解.....11
2.4 本章小结.....12
第三章 基于模型融合的血糖预测模型.....13
3.1 研究背景.....13
3.2 基于粒子群优化的融合模型设计.....14
3.3 基于粒子群优化的融合模型构建.....15
3.3.1 数据来源.....15
3.3.2 数据预处理.....15
3.3.3 粒子群优化基学习器.....18
3.3.4 stacking 模型融合.....19
3.4 实验结果及分析.....21
3.4.1 实验环境.....21
3.4.2 模型评价指标.....21
3.4.3 滤波结果分析及对比.....22
3.4.4 优化结果分析及对比.....23
3.4.5 模型融合结果分析及对比.....25

中国知网 https://www.cnki.net

3.5 本章小结.....31
第四章 基于增量学习的血糖预测实时更新模型.....32
4.1 研究背景.....32
4.2 实时更新模型的总体设计.....33
4.3 实时更新模型的构建.....34
4.3.1 数据来源.....34
4.3.2 异常值检测.....34
4.3.3 信号分解实验.....35
4.3.4 增量学习实时更新.....37
4.4 实验结果及分析.....39
4.4.1 实验环境.....39
4.4.2 异常值检测结果分析.....39
4.4.3 信号分解结果分析及对比.....40
4.4.4 增量学习结果分析及对比.....43
4.5 本章小结.....47
第五章 基于机器学习的血糖预测系统.....48
5.1 设计背景.....48
5.2 技术概述.....48
5.2.1 MongoDB 数据库.....48
5.2.2 TDengine 时序数据库.....49
5.2.3 Vue 前端.....49
5.2.4 SpringCloud 框架.....50
5.3 系统设计.....50
5.3.1 数据库设计.....50
5.3.2 框架设计.....54
5.3.3 功能概述.....55
5.4 系统实现.....57
5.4.1 初始登录界面.....57
5.4.2 数据统计界面.....57
5.4.3 用户信息管理界面.....59
5.4.4 血糖预测界面.....60
5.5 本章小结.....61
第六章 总结与展望.....62
6.1 研究总结.....62
6.2 研究展望.....63
参考文献.....64

中国知网 https://www.cnki.net

专用术语注释表

缩略词说明：

MAPE	Mean Absolute Percentage Error	平均绝对百分比误差
RMSE	Root Mean Squared Error	均方根误差
MSE	MSE	均方误差
BG	Blood Glucose	血糖
ML	Machine Learning	机器学习
ANN	Artificial Neural Network	人工神经网络
LSTM	Long Short Term Memory	长短期记忆网络
CGMS	Continues Glucose Monitoring System	动态血糖监测系统
AR	Autoregressive model	自回归模型
RNN	Recurrent Neural Network	循环神经网络
XGBoost	EXtreme Gradient Boosting	极端梯度提升
LightGBM	Light Gradient Boosting Machine	梯度提升树
CatBoost	Category Boosting	对称决策树
PSO	Particle Swarm Optimization	粒子群优化算法
DWT	Discrete Wavelet Transform	离散小波变换
EMD	Empirical Mode Decomposition	经验模态分解
IMF	Intrinsic Mode Function	本征模函数
KF	Kalman Filter	卡尔曼滤波

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景与意义

糖尿病是一种以慢性高血糖为特征表现的代谢性疾病，它是由于各种原因造成的，往往伴随着因胰岛素分泌或者胰岛素功能缺陷而导致的糖、蛋白质、脂肪、水和机体内电解质等一系列代谢紊乱。根据相关数据研究表明，我国糖尿病患病率居世界首位。糖尿病很难治愈，并可能导致许多并发症，严重威胁患者的生命安全[1]。

流行病学调查显示，中国成年人糖尿病患病率为 12.8%，即每 8 个成年人中存在 1 名糖尿病患者。中国糖尿病患者总人数超过 1.4 亿。中国糖尿病患者中超重肥胖的人数占比达到 60%至 70%，肥胖是 2 型糖尿病病情恶化的主要驱动力。另外，糖尿病发病呈年轻化趋势，早发型糖尿病（40 岁之前被确诊为糖尿病）占到糖尿病患者总数的 1/3。中国病程在 5 年以上的糖尿病患者中 1/3 已存在并发症，病程 8 年以上糖尿病患者中 60%的人出现并发症。

糖尿病是由于胰岛素分泌缺陷或作用缺陷导致的以血糖水平增高为特征的代谢性疾病，其可以分为以下几类：1 型糖尿病、2 型糖尿病、其他特殊类型糖尿病和妊娠期糖尿病。其中 1 型糖尿病发病原因为胰岛β细胞分泌胰岛素功能缺陷，多见于青少年，很少肥胖，儿童发病急骤、成人发病隐匿；2 型糖尿病是最常见的糖尿病类型，由于多发于成年，又称成人发病型糖尿病。该病由多种病因导致体内胰岛素分必不足或者人体不能有效利用胰岛素，导致血糖水平持续升高。在高血糖环境下，大血管、微血管、神经等都会发生病变，进而危害心脏、肾脏、眼睛等器官；其他特殊类型糖尿病是具有明确病因的糖尿病，比如长期使用激素者、Cushing、胰腺疾病；妊娠期糖尿病是妊娠期间的糖尿病，多发生于妊娠期 24 周后，主要和胰岛素抵抗增加或者是胰岛素分泌不足有关[2]。

目前的医疗水平和条件无法根治糖尿病，只有尽早发现和积极的预防才能减小糖尿病对身体的伤害以及降低相关并发症发生的可能性。然而，大规模获取体检人员的血糖值不仅消耗医护人员的人力，还耗费大量医疗耗材，给国家医疗财政带来沉重负担。随着机器学习的快速发展，它已成为各个领域不可或缺的一部分，医疗领域也不例外。因此，合理利用机器学习方法构建血糖值预测模型，可以实现对血糖值的精准预测。这样，医护人员就能及时对高血糖人群进行预警或早期治疗，降低患糖尿病的风险和减少疾病对身体的损害，同时也有助于节省国家大量的医疗开支。

中国知网 https://www.cnki.net

1.2 国内外研究现状

当前，国内外众多专家学者在血糖值预测领域做出了显著贡献，提出了多种不同的预测方法。这些方法主要可分为两大类：一类是基于人体生理模型的预测方法，另一类则是基于数据驱动的预测方法。基于人体生理模型的预测方法依赖于对人体生理机制的深入理解，通过建立数学模型来模拟血糖浓度的动态变化过程，包括胰岛素分泌、胰高血糖素反应等。而基于数据驱动的预测方法则通过分析大量的实际血糖数据，运用统计学和机器学习技术，寻找数据中的规律和模式，从而实现对未来血糖值的预测。

1.2.1 基于生理模型的血糖值预测

基于生理模型的血糖值预测方法主要基于医学理论，可分为最大模型和最小模型。基于极大值模型的血糖预测方法的基本思想是通过最大限度地覆盖人体的所有代谢信息，并将这些信息进行整合，模拟血糖值的代谢过程。基于最小模型的血糖值预测方法相对简单，它的基本思想是不包含其他人体的代谢信息，只用核心方程来表示血糖值与胰岛素的关系。2021 年 Wang 等人提出了一种 RG 超参数优化方法，基于随机搜索和网格搜索的顺序使用，用于改进提升集成学习模型的血糖水平预测。基于通过体检方法收集的历史医学数据，使用 40 个人体健康指标，对患者的血糖水平进行间接预测。用真实临床数据进行的实验证明，所提出的 RG 双重优化方法有助于提高其丰富的四种最先进的 Boosting 集成学习模型的预测性能，实现了 1.47%到 24.40%的均方误差改进和 0.75%到 11.54%的均方根误差改进[3]。同年 Obeidat 等人基于机器学习(Machine Learning, ML)的模型用于跟踪患者的葡萄糖水平并预测适当的胰岛素量，并使用了人工神经网络(Artificial Neural Network, ANN)模型来预测血糖，实验结果显示该方法均方误差为 5.79[4]。2022 年 Iacono 等人为 UVA/Padova 模拟器的 100 名患者提出了个性化长短期记忆网络(Long Short Term Memory, LSTM)模型，血糖(Blood Glucose, BG)水平的预测范围为 40 分钟，将膳食、胰岛素和过去的 BG 值作为输入，实验结果表明所提出的具有简单架构的 LSTM 相对于文献获得了令人满意的结果（RMSE=7.67，FIT=75.86%）[5]。2023 年 Jaloli 等人提出了基于卷积神经网络和长短期记忆单元的融合模型，以根据历史血糖测量值、膳食信息和胰岛素摄入量来预测 30 分钟、60 分钟和 90 分钟预测范围的血糖水平，实验研究表明与文献中的现有方法相比，该方法实现了更好的血糖预测，并且由于其普遍性，显示出了现实生活应用的潜力[6]。由于人体生理代谢是一个很复杂的过程，会受到很多外界因素影响，而生理模型建立又需要考虑个体差异的影响并且需要掌握很多药理学的知识，因此以

中国知网 https://www.cnki.net

生理模型对血糖值进行预测往往不能保证准确度。

1.2.2 基于数据驱动的血糖值预测

动态血糖监测系统(Continues Glucose Monitoring System, CGMS) [7, 8]是血糖监测领域的一项创新型技术突破，通过持续监测皮下细胞间液的葡萄糖浓度而反映血糖水平[9]。血糖平衡是衡量糖尿病患者健康状况的重要标准，目前尚无根治糖尿病的方法，但如果可以快速准确地预测患者的血糖水平对于糖尿病患者的病情控制和治疗具有重要意义。基于 CGMS 提供的数据，许多专家学者通过建立数据驱动模型来对血糖值进行预测，例如自回归[10-12](Autoregressive model, AR)模型、支持向量机[13, 14]、神经网络[15, 16]等。2018 年 Hamdi 等人使用支持向量机和差分进化算法对 1 型糖尿病的血糖值进行预测，实验结果证明基于差分进化算法的支持向量机模型实现了高预测精度[17]。同年 Ali 等人提出了一种基于人工神经网络的新方法用来预测 1 型糖尿病的血糖水平，实验结果表明该方法是准确的、自适应的[18]。2019 年 Dong 等人提出了一种新的 BG 预测方法-Clu-RNN，它是基于 RNN5 将聚类的处理整合到经典循环神经网络(Recurrent Neural Network, RNN)中，经过实验表明，该方法与支持向量机和其它 RNN 方法相比血糖预测精度方面有一定的改进[19]。2020 年 Alfian 等人利用 XGBoost 模型对 1 型糖尿病患者未来血糖值进行预测，实验结果表明基于 XGBoost 模型的血糖预测精度优于其他模型[20]。同年 Wang 等人使用了较为新颖的 LightGBM 模型并使用贝叶斯优化算法优化模型参数，最后预测血糖水平，实验证明优化后的模型具有比 XGBoost 模型和 CatBoost(Category Boosting)模型更高的预测精度[21]。同年滕建丽等人提出一种基于门控循环网络(Gated Recurrent Unit, GRU)的血糖预测模型，实验结果表明，该方法具有较高预测精度，其预测步长为 20 步的均方根误差和平均绝对百分误差分别为 0.7612mol/L 和 7.3427%，可为血糖闭环控制系统提供支持[22]。2023 年童梦等人提出一种基于变分模态分解和粒子群优化长短时记忆网络的血糖浓度短期预测模型，实验结果表明该模型具有更高的预测精度[23]。

通过研究机器学习和人工智能技术，基于某公司 CGMS 提供的血糖数据，本文选择机器学习中的集成学习和增量学习为理论基础，先是通过粒子群优化算法对 XGBoost 模型、LightGBM 模型进行超参数寻优，并通过 stacking 模型融合的思想将优化后的模型进行融合，使用融合后的模型对血糖值进行预测，后通过信号分解算法和增量学习方法，最后作出血糖值预测结果的对比。通过对血糖值的精准预测，医护人员就能及时对高血糖人群进行预警或早期治疗，降低患糖尿病的风险和减少疾病对身体的损害，同时也有助于节省国家大量的医疗开支。

中国知网 https://www.cnki.net

1.3 本文主要内容和结构安排

1.3.1 本文研究主要内容

通过上述的研究不难发现以往对于血糖值预测的研究中，大多数学者采用的都是单一模型，虽然这些模型都有着不错的性能，但参数较多，不同参数的选择对实验结果都有一定的影响。另外，单一的模型具有其局限性，处理不确定数据往往效果不尽如意。因此，融合不同的模型，发挥各自的优势，可以进一步提高血糖预测精度。为解决上述问题，本文基于 CGMS 提供的血糖数据，提出一种基于粒子群优化和模型融合的血糖预测方法。该方法主要通过粒子群优化算法对 XGBoost 和 LightGBM 模型进行超参数优化，然后基于 stacking 模型融合思想，将优化后的 XGBoost 和 LightGBM 模型作为基学习器，贝叶斯回归模型作为元学习器进行模型融合，以此提高血糖预测精度。

另外传统的机器学习采用的是批量学习(batch learning)方法，需要事先准备好数据，并进行一次性的训练。为了满足实时更新的需求，往往需要放弃以前的学习成果，系统需根据新增加的数据和过去所有数据一起重新学习和训练。显然如果在新数据增加后，放弃以前的学习成果，重新学习全部数据，会导致消耗大量的时间和空间资源[24, 25]。基于此，本文又提出一种基于增量学习的血糖预测实时更新模型。该方法主要通过异常值检测和信号分解对血糖原始信号进行分解，提取不同时间尺度的局部特征信息，以降低血糖预测误差。然后基于 XGBoost 和 LightGBM 增量学习方法，每当新增数据时，并不需要重新训练模型，而是在原有的知识库的基础上，仅根据新增数据所引起的变化对模型实时更新。

1.3.2 本文结构安排

本文由六个章节构成，每个章节的具体安排如下：

第一章 绪论。该部分首先阐述了血糖预测的研究背景与意义，然后对国内外现有的血糖值预测方法的研究现状进行简单的介绍，最后根据目前存在的问题，提出了本课题的研究目标及内容。

第二章 相关背景知识介绍。该部分首先介绍了粒子群优化算法，后介绍了集成学习的算法模型，其中着重介绍 XGBoost 模型、LightGBM 模型和 stacking 模型融合。最后介绍了信号分解算法，其中包括离散小波变换和经验模态分解。

第三章 基于粒子群优化和模型融合的血糖预测模型。该部分首先通过卡尔曼滤波算法和

中国知网 https://www.cnki.net

z-score 方法对传感器数据进行预处理，再利用粒子群优化算法对 XGBoost 和 LightGBM 模型进行超参数优化。最后，以优化后的 XGBoost 和 LightGBM 模型为基学习器，结合贝叶斯回归模型作为元学习器，对传感器数据进行训练和测试，实现对血糖值的较为准确的预测。

第四章 基于增量学习的血糖预测实时更新模型。该部分首先通过箱线图法进行异常值检测，对卡尔曼滤波后的数据进行处理，以提高数据质量。然后，采用离散小波变换和经验模态分解对传感器信号进行分解，比较两者的效果，选择性能更优的方法。最后，利用 XGBoost 和 LightGBM 两种增量学习方式对模型进行新数据的训练和测试，实现在减少模型训练时间的同时，对新数据的血糖值进行更为准确的预测。

第五章 基于机器学习的血糖预测系统。该部分成功实现了第三章和第四章提出的基于粒子群优化和模型融合的血糖预测模型，以及基于增量学习的血糖预测实时更新模型。同时，设计并实现了基于机器学习的 CGM 血糖预测系统。该系统采用模块化设计，包括血糖数据统计模块、用户信息管理模块和用户血糖预测模块。

第六章 总结与展望。该部分对本文的主要工作进行了总结，以及分析其中的不足之处，并对下一步的研究方向进行展望。

中国知网 https://www.cnki.net

第二章 相关背景知识介绍

本章对粒子群优化算法、集成学习算法模型和信号分解算法进行了总结概括，为后续的实验提供了有效的理论支撑。

2.1 粒子群优化算法

粒子群优化算法(Particle Swarm Optimizationd, PSO)[26-28]是一种基于鸟类捕食行为研究的进化算法。该算法基本思想是通过群体中个体之间的协作和信息共享来寻找最优解。

2.1.1 基本原理

在 d 维连续搜索空间中，对粒子群中的第 i（i=1, 2, ……, n）个粒子进行定义：$x_i^k = (x_{i1}^k,\ x_{i2}^k, \dots, x_{id}^k)$，表示第 i 个粒子在 k 时刻的位置；每个粒子经历过的最优位置记为$p_i^k = (p_{i1}^k,\ p_{i2}^k, \dots, p_{id}^k)$，群体经历过的最优位置记为$p_g^k = (p_{g1}^k,\ p_{g2}^k, \dots, p_{gd}^k)$；根据上述理论，群体中各粒子在 k+1 时刻的速度v_{id}^{k+1}、位置x_{id}^{k+1}更新公式如下所示：

$$v_{in}^{k+1} = w^k v_{id}^k + c_1 r_1 \left(p_{id}^k - x_{id}^k\right) + c_2 r_2 (p_{gd}^k - x_{id}^k) \tag{2.1}$$

$$x_{id}^{k+1} = x_{id}^k + v_{id}^{k+1} \tag{2.2}$$

其中 w 表示惯性权重，k 表示当前迭代次数，r_1，r_2为介于(0,1)的随机数，c_1，c_2是加速因子，分别为个体学习因子和群体学习因子。

2.1.2 算法伪代码

粒子群优化算法(PSO)伪代码如下：

表 2.1 粒子群优化算法伪代码

算法：粒子群优化算法(PSO)
输入： 每个粒子的位置 x、速度 v 粒子的维度 d，学习因子 c1、c2 输出：粒子的最优位置 x

中国知网 https://www.cnki.net

```
FOR each particle i    // 遍历每个粒子
  FOR each dimension d    //d 维搜索空间
    Initialize position $x_{id}$ randomly within peimissible range //初始化粒子位置
    Initialize velocity $v_{id}$ randomly within peimissible range //初始化粒子速度
  END FOR
END FOR
Iteration k=100   //设置迭代次数
DO
  FOR each particle i
    Calculate fitness value   //计算粒子适应度（适应度函数为：MAPE）
    IF the fitness value is better than $p_{id,pbest}^{k}$ in history   //粒子最优位置
      Set current fitness value as the $p_{id,pbest}^{k}$
    END IF
  END FOR
  Choose the particle having the best fitness value as the $p_{d,gbest}^{k}$ //群体最优位置
  FOR each particle i
    FOR each dimension d
      Calculate velocity according to the equation
      $v_{id}^{k+1} = \omega v_{id}^{k} + c_1 r_1 (p_{id,pbest}^{k} - x_{id}^{k}) + c_2 r_2 (p_{d,gbest}^{k} - x_{id}^{k})$ //更新粒子的速度
      Update particle position according to the equation
      $x_{id}^{k+1} = x_{id}^{k} + v_{id}^{k+1}$   //更新粒子的位置
    END FOR
  END FOR
  k = k+1
WHILE maximum iterations or minimum error criteria are not attained   //终止条件
```

2.2 集成学习算法

2.2.1 XGBoost

XGBoost(EXtreme Gradient Boosting)[29, 30]是一种基于梯度提升树的机器学习算法，它在

中国知网 https://www.cnki.net

解决分类和回归问题上表现出色。它是由陈天奇在 2014 年开发的，如今已成为机器学习领域中最流行和强大的算法之一。XGBoost 结合了梯度提升框架和决策树模型，通过迭代地训练一系列的决策树来逐步改进预测性能。它的目标是优化损失函数，使得预测值与实际值之间的误差最小化[31]。

XGBoost 是一种集成学习方法，通过将多个弱学习器（通常是决策树）进行集成来构建一个更强大的预测模型。下面是 XGBoost 的算法原理：

（1）损失函数：XGBoost 的目标是最小化一个定义在预测值和实际值之间的损失函数。常用的损失函数包括平方损失函数（回归问题）和对数损失函数（二分类和多分类问题）。

（2）基础模型：XGBoost 使用回归树作为基础模型，每个回归树由一系列决策节点和叶节点组成。初始时，XGBoost 使用一个简单的基础模型（如一个叶节点）作为起点。

（3）残差计算：在每轮迭代中，XGBoost 通过计算当前模型的预测值与实际值之间的残差来进行训练。这里的残差表示当前模型对样本的预测结果与真实值之间的差异。

（4）损失函数近似：为了优化损失函数，XGBoost 使用泰勒展开（Taylor expansion）来近似损失函数。将损失函数进行二阶泰勒展开后，可以得到一个简化的目标函数，其中包括关于残差的一阶导数和二阶导数。

（5）弱学习器训练：XGBoost 以梯度下降的方式训练每个回归树。根据目标函数的一阶导数和二阶导数，XGBoost 计算每个样本在当前模型下的梯度和二阶梯度。然后，通过拟合一个新的回归树来近似梯度和二阶梯度，使得模型能够更好地预测这些样本的残差。

（6）加权组合：XGBoost 使用一定的步长（学习率）将新构建的回归树与当前模型进行加权组合。这样，每轮迭代都会得到一个更新的模型，它在之前模型的基础上进一步提高了预测能力。

（7）正则化：为了控制模型的复杂度和防止过拟合，XGBoost 引入了正则化项。正则化项包括树的复杂度和叶节点权重的惩罚项，可以限制树的深度和叶节点的权重。

（8）迭代训练：通过多轮迭代，XGBoost 不断优化模型的预测能力，直到达到停止条件（如达到指定的迭代次数、模型在验证集上的性能不再提升等）。

（9）预测：训练完成后，可以使用 XGBoost 模型进行预测。对于回归问题，预测值为多个回归树的加权求和；对于分类问题，预测值可以通过使用 softmax 函数将多个回归树的输出转化为概率。

中国知网 https://www.cnki.net

2.2.2 LightGBM

LightGBM(Light Gradient Boosting Machine)[32-34]是一种基于梯度提升树(Gradient Boosting Decision Tree)的机器学习算法，它是由微软公司开发的一种高效、快速的梯度提升框架。与传统的梯度提升树算法相比，LightGBM 在训练和预测的速度上具有较大的优势。这主要得益于以下几个方面的改进：

（1）基于直方图的决策树算法：LightGBM 使用了基于直方图的决策树算法，将连续特征离散化成离散的直方图特征，从而减少了数据的存储空间和计算复杂度。这种离散化方法可以降低特征处理的复杂性，并且能够更好地处理高维稀疏数据。

（2）垂直并行化训练算法：LightGBM 使用了一种称为 GOSS(Gradient-based One-Side Sampling)的采样方法和 EFB(Exclusive Feature Bundling)的特征捆绑方法，使得模型在训练过程中可以进行高效的垂直并行化计算。这样可以加快模型的训练速度，并且在处理大规模数据集时尤为有效。

（3）Leaf-wise 生长策略：传统的梯度提升树算法是按层生长的，而 LightGBM 使用了一种称为 Leaf-wise 的生长策略。Leaf-wise 生长策略每次选择当前最优的叶子节点进行分裂，这样可以更快地找到损失函数减小最快的方向，从而加快了模型的训练速度。

（4）内存优化：LightGBM 使用了特殊的数据结构和压缩技术，减少了内存的使用。它采用了按列存储的方式，可以减少内存访问的次数，提高数据读取的效率。此外，LightGBM 还支持将数据集加载到内存中的子样本中进行训练，以减少内存的占用。

2.2.3 stacking 模型框架

stacking 集成学习的基本思想是：使用原始数据集训练多个基学习器，每个基学习器输出的预测结果作为新的数据集输入至元学习器中，元学习器的输出结果则作为最终的预测结果[35-37]，如图 2.1 所示。

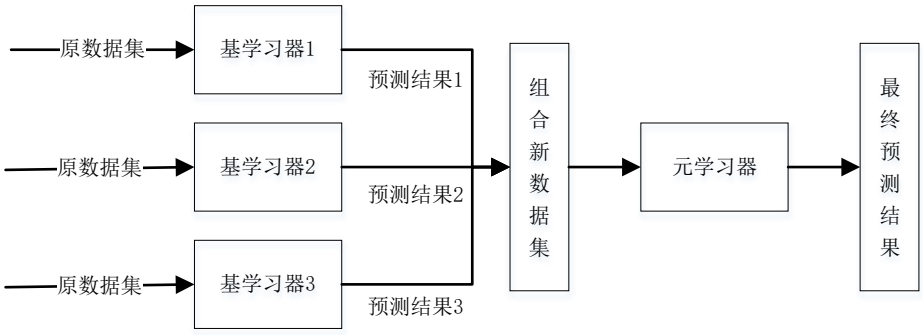

图 2.1 stacking 集成学习方式

中国知网 https://www.cnki.net

其中在训练 N 个基学习器的过程中，采用了 K-fold 交叉验证法。首先，将数据集分为训练集和测试集，然后通过非重复采样将训练集随机分为 K 份，其次，每次选择其中 K-1 份作为基学习器的训练集，1 份作为验证集。重复操作 K 次，每个子集都有机会成为验证集。进一步地，用每次训练集训练得到的模型预测验证集，得到一列新的数据，如此循环，将 N 个基学习器的预测结果视为第二层元学习器的训练集。同时，每个基学习器的 K 个模型也要对测试集做出预测，预测结果取其算术平均值，然后将再把 N 个基学习器的所有预测结果组合起来，作为元学习器的测试集。最后，使用训练集训练好的元学习器预测测试集，其结果作为最终的预测结果。具体流程如图 2.2 所示。

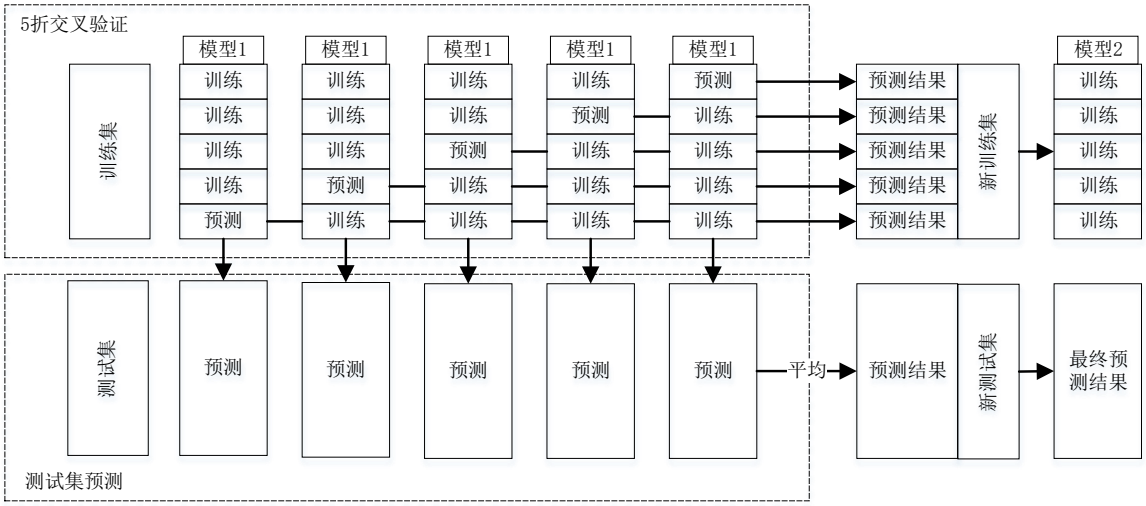

图 2.2 stacking 模型融合原理图

2.3 信号分解算法

2.3.1 离散小波变换

离散小波变换（Discrete Wavelet Transform，简称 DWT）[38-40]是一种用于信号和图像处理的数学技术，它通过对基本小波的尺度和平移进行离散化来实现。在小波变换中，通常使用二进制小波作为小波变换函数，即将整个时域或整个频域划分为以 2 为底数的矩形区域。以下是离散小波变换的主要步骤和原理：

（1）尺度和小波基函数的构造：小波变换使用一个具有快速衰减性和震荡性的母函数，并通过尺度因子 a（伸缩因子）和平移因子 t 对其进行伸缩和平移，得到一个函数家族（小波基函数）。这两个参数是小波基中最重要的组成部分，它们决定了小波变换的基本思想和能够覆盖的频率范围。

（2）时-频分解：任意能量有限的信号可以通过其函数族进行时-频分解。小波基在时-频

中国知网 https://www.cnki.net

相平面上的时间-频率窗口是可变的，这使得它可以适应不同分辨率的需求。这意味着小波变换能够在不丢失太多信息的情况下压缩数据，同时保持对图像细节的良好描述。

（3）阈值处理和高频重构：在进行小波变换之前，可以对高频小波系数和非零低频小波系数应用阈值处理，以减少噪声的影响。之后，可以使用小波重构函数将经过阈值处理后的小波系数以及高频部分和低频部分重新组合，从而获得重建后的信号值。

2.3.2 经验模态分解

经验模态分解(Empirical Mode Decomposition, EMD)[41-44]是依据数据自身的时间尺度特征来进行信号分解，无需预先设定任何基函数，是一种时频域信号处理方式。EMD 在处理非平稳和非线性数据方面具有明显的优势，适合分析非线性非平稳的信号序列，具有较高的信噪比。它的基本原理如下：

（1）求出原始信号X(t)的极大值和极小值点，然后使用曲线插值方法对这些极值点进行拟合，得到信号的上包络线$X_{max}(t)$和下包络线$X_{min}(t)$。

（2）对上下包络线求平均值：

$$m_1(\mathrm{t}) = \frac{X_{max}(t)+X_{min}(t)}{2} \tag{2.3}$$

（3）对原始信号X(t)与平均包络$m_1(\mathrm{t})$进行相减，得到余下信号$d_1(t)$。一般来说，对于平稳信号而言，它是原始信号X(t)与的第一个模态函数(Intrinsic Mode Function, IMF)。但对于非平稳信号，信号并不是在某一个区域内单调递增的，而是会出现拐点。这些能反映原始信号X(t)的具体特征的拐点若未被选中，则得到的第一阶模态函数并不准确，也就是通常得到的$d_1(t)$并不满足 IMF 的两个条件，所以需要继续进行筛选。

（4）对余下信号$d_1(t)$进行步骤（1）到步骤（3）的处理，直到 SD（筛分门限值，一般取值 0.2-0.3）小于门限值时才停止，这样得到最终合适的第一阶模态分量$c_1(t)$，即第一个 IMF。其中 SD 求法如下：

$$\mathrm{SD} = \sum_{t=0}^{T}\left[\frac{|d_{k-1}(t)-d_k(t)|^2}{d_{k-1}^2(t)}\right] \tag{2.4}$$

（5）对信号X(t)和$c_1(t)$求差，得到第一阶残差量$r_1(t)$，使用$r_1(t)$替代原始信号X(t)进行步骤（1）到（5）的处理，重复 n 次后可获取第 n 阶模态函数$c_n(t)$和最终符合标准的残差量$r_n(t)$。原始信号X(t)经 EMD 分解的表达式为：

$$\mathrm{X(t)} = \sum_1^n c_n(t) + r_n(t) \tag{2.5}$$

中国知网 https://www.cnki.net

2.4 本章小结

本章首先介绍了粒子群优化算法，后介绍了集成学习的算法模型，其中着重介绍 XGBoost 模型、LightGBM 模型和 stacking 模型融合。最后本章介绍了信号分解算法，其中包括离散小波变换和经验模态分解。本章介绍的相关理论知识为后续章节的实验奠定了理论基础。

中国知网 https://www.cnki.net

第三章 基于模型融合的血糖预测模型

糖尿病是由于血糖浓度升高而导致的胰岛素分泌不足而形成的代谢性疾病，糖尿病尽管表面看上去与常人无异，但血糖一旦控制不好，将会导致严重后果。在糖尿病的治疗中，及时监测血糖尤为重要。血糖结果有助于评估糖尿病患者糖代谢紊乱的程度，帮助患者制定合理的降糖方案。本章基于某公司提供的血糖数据，提出一种基于模型融合的血糖预测方法。该方法主要通过粒子群优化算法对 XGBoost 和 LightGBM 模型进行超参数优化，然后基于 stacking 模型融合思想，将优化后的 XGBoost 和 LightGBM 模型作为基学习器，贝叶斯回归模型作为元学习器进行模型融合，以此提高血糖预测精度。

3.1 研究背景

CGMS 是血糖监测领域的一项创新型技术突破。通过持续监测皮下细胞间液的葡萄糖浓度而反映血糖水平。血糖平衡是衡量糖尿病患者健康状况的重要标准，目前尚无根治糖尿病的方法，但如果可以快速准确地预测患者的血糖水平对于糖尿病患者的病情控制和治疗具有重要意义。基于 CGMS 提供的数据，国内外研究人员提出了多种预测方法，通过建立数据驱动模型来对血糖值进行预测，例如自回归模型、支持向量机、神经网络等。

2020 年 Alfian 等人利用 XGBoost 模型对 1 型糖尿病患者未来血糖值进行预测，实验结果表明基于 XGBoost 模型的血糖预测精度优于其他模型[20]。同年 Wang 等人使用了较为新颖的 LightGBM 模型并使用贝叶斯优化算法优化模型参数，最后预测血糖水平，实验证明优化后的模型具有比 XGBoost 模型和 CatBoost 模型更高的预测精度[21]。虽然这些模型都有着不错的性能，但参数较多，不同参数的选择对实验结果都有一定的影响。另外，单一的模型具有其局限性，处理不确定数据往往效果不尽如意。因此，融合不同的模型，发挥各自的优势，可以进一步提高血糖预测精度。

为解决上述问题，本章基于某公司 CGMS 提供的血糖数据，提出一种基于模型融合的血糖预测方法。该方法主要通过粒子群优化算法对 XGBoost 和 LightGBM 模型进行超参数优化，然后基于 stacking 模型融合思想，将优化后的 XGBoost 和 LightGBM 模型作为基学习器，贝叶斯回归模型作为元学习器进行模型融合，以此提高血糖预测精度。下面将从融合模型的总体设计、构建两个方面进行详细介绍。

中国知网 https://www.cnki.net

3.2 基于粒子群优化的融合模型设计

本章主要涉及对某公司 CGMS 提供的血糖数据进行了一些数据预处理工作，在预处理完成之后，针对选取的模型进行超参数优化。最终，本章采用 stacking 模型融合的方法，将超参数经过优化的、接近最优的模型与元学习器相结合，以实现对血糖值的更为精确的预测。基于粒子群优化的融合模型的基本流程如图 3.1 所示，展示了整个过程的关键步骤和交互。这种方法不仅强调了对数据的有效处理，还突显了模型超参数调整的重要性。通过这种综合的方法，本章能够在血糖值预测方面取得更为显著的成果。

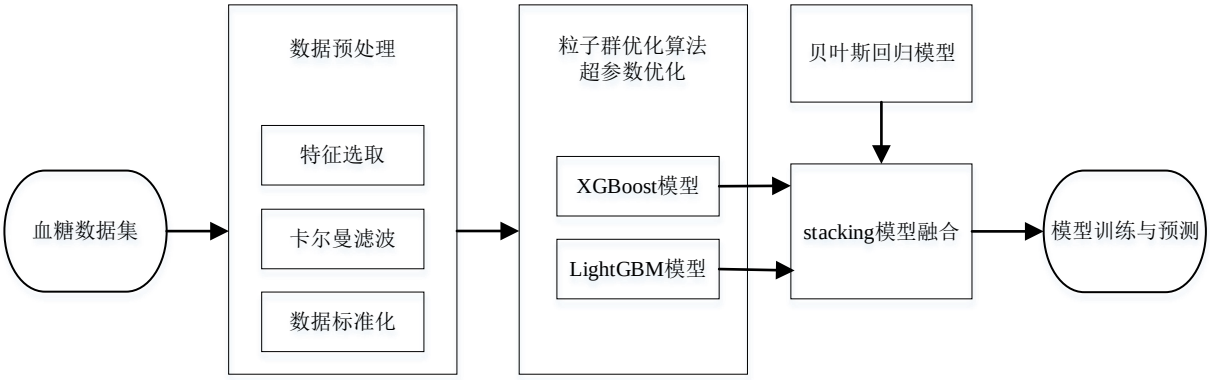

图 3.1 融合模型总体流程

从图 3.1 中可以看出，第一步是对血糖数据集进行了详细的预处理，这一步骤包括使用热力图对数据集中的数据项进行特征筛选，以挑选出最具价值的特征数据。接下来引入了卡尔曼滤波算法对电流信号进行平滑降噪处理，以提高数据的质量和可解释性。最后对血糖数据进行标准化处理，为后期模型训练做准备。

第二步是采用粒子群优化算法对两个强大的机器学习模型：XGBoost 和 LightGBM 模型进行超参数优化，通过精心调整模型超参数，旨在提高模型的性能和泛化能力。这个步骤的目标是找到最佳的超参数组合，以在后续的预测任务中取得最佳效果。

最后一步先是使用优化后的模型和贝叶斯回归模型进行 stacking 模型融合，该融合后的模型能够从各个子模型的预测结果中学习，以提高整体的预测性能。最后使用标准化后的数据对融合模型进行训练，以实现对血糖值的准确预测。

总的来说，这一研究框架整合了特征选取、数据预处理、超参数优化和模型融合等多个步骤，以全面提升血糖预测模型的性能和鲁棒性。

中国知网 https://www.cnki.net

3.3 基于粒子群优化的融合模型构建

3.3.1 数据来源

本章所用的数据来源于某公司血糖仪数据，数据包含 2022 年 5 月 24 日 33 位患者的血糖数据和 2022 年 6 月 16 日 10 位患者的血糖数据，分别共计 464438 条和共计 113591 条。其中 5 月 24 日的数据作为模型的训练集，6 月 16 日数据中含有指尖采血测量的血糖浓度值（即实际血糖值）的数据作为测试集，共计 1281 条。数据主要数据项见表 3.1。

表 3.1 主要数据项

数据项	说明
itime	运行时间
iw	工作电流
ib	空白电流
t	体表温度
cno	实际血糖值
bg	传感器校准值
base_ref	CGM 浓度
Iw_net	实际工作电流
ref	无校准血糖值
STD	校准血糖值

表格中的 itime 指传感器当前的运行时间，每三分钟一次；cno 是通过指尖采血得到的实际血糖浓度；bg 是校准值，不为 0 时说明此时 bg 值校准 CGM，base_ref 是凯立特算法产生的血糖值；STD 是根据最近一次指尖采血校准后的血糖值。

3.3.2 数据预处理

（1）特征选取

在本章的数据集中，主要包含了多个关键的数据项，这些项对于血糖的预测具有重要的作用。这些数据项包括传感器运行时间、工作电流信号值、空白电流信号值、体表温度、实际血糖值、校准值、CGM 浓度、实际参与血糖计算的电流值、无校准情况下凯立特算法产生的血糖浓度值，以及根据最近一次指尖采血值校准后的血糖值。

在这些数据项中，其中一些特征是通过某公司凯立特算法生成的输出值，在这里是不使

中国知网 https://www.cnki.net

用的，本章的预测结果也会与之对比。最终，本章选择了 4 个关键特征：传感器工作电流信号值(iw)、空白电流信号值(ib)、体表温度(t)、实际参与血糖计算的电流值(Iw_net)。此外，为了进一步扩增特征，经过分析后添加传感器当前的工作小时值(hour)以及传感器工作时长（分钟制）(time_length)为新特征。图 3.2 展示了这些特征之间的相关系数矩阵热力图，其中数值越大表示特征之间的相关性越高。通过这样的分析能够更好地理解各个特征之间的关系，为后续的建模和预测提供有力支持。

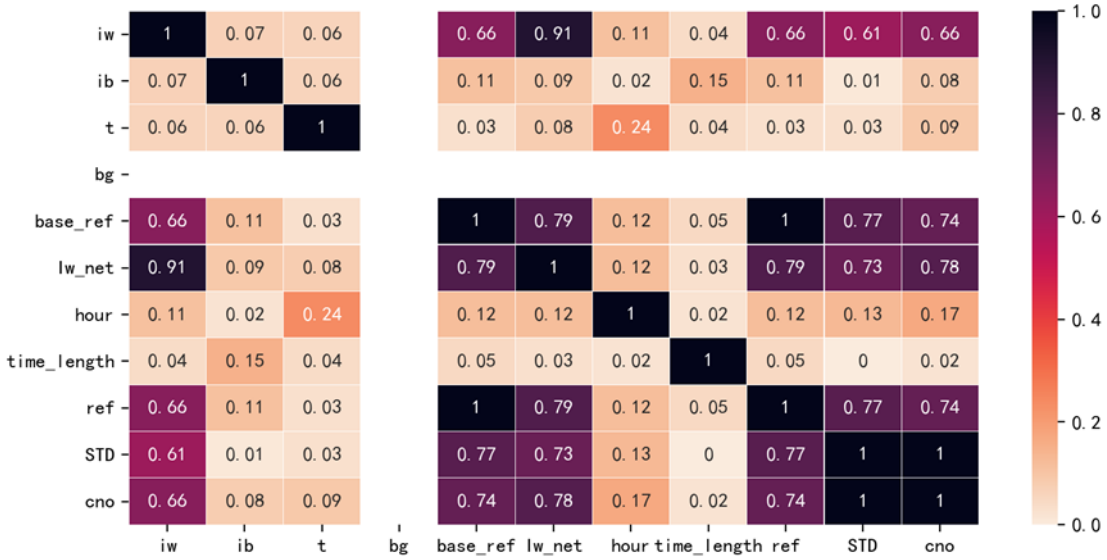

图 3.2 特征相关稀疏矩阵热力图

通过观察图 3.2 可以得出如下结论。首先，bg 和 cno 以及其他一些特征之间并不存在明显的相关性。另外，base_ref、ref 和 STD 与 cno 之间存在较高的相关性，但根据第 3.1 节的信息，它们是某公司凯利特算法的输出值和校准值，因此不能作为独立特征使用。另外，新添加的特征 hour、time_length 与 cno 具有一定的相关性，因此它们可以作为有效的特征使用。基于这些观察和分析，最终选择的特征集包括：传感器工作电流信号值(iw)、空白电流信号值(ib)、体表温度(t)、实际参与血糖计算的电流值(Iw_net)、传感器当前的工作小时值(hour)以及传感器工作时长（分钟制）(time_length)。这一步的特征选择是为了确保模型使用的数据具有较高的信息量和预测性能，从而提高对血糖值的准确预测能力。

（2）卡尔曼滤波算法

从 CGMS 获取的血糖数据中的传感器的电流信号存在一定的毛刺和噪声，若将这些原始信号直接输入模型，可能会对模型的效果产生负面影响。因此，本章需要对原始数据进行平滑降噪处理，以提高模型的鲁棒性和性能。

卡尔曼滤波(Kalman Filter)[45, 46]算法，是一种递推预测滤波算法。它为估计过程状态和最小化估计的均方误差提供了一种有效且可计算的方法。卡尔曼滤波器应用广泛且功能强大：它可以估计信号的过去和当前状态，甚至能估计将来的状态，在本文这种传感器信号连续变

中国知网 https://www.cnki.net

化的系统中使用卡尔曼滤波是非常理想的。该算法主要包括两个关键步骤，即预测过程和修正过程[47]，以下是具体的步骤：

（a）预测过程：通过上一时刻状态估计下一时刻的状态，计算公式如下：

$$x_k = Ax_{k-1} + Bu_k \tag{3.1}$$

$$P_k = AP_{k-1}A^T + Q \tag{3.2}$$

其中x_k和u_k分别表示先验估计和系统控制量，A 和 B 分别是状态转移矩阵和控制矩阵，P 和 Q 分别是误差协方差和过程噪声。

（b）修正过程：根据当前时刻的状态估计与观测状态，估计出最优状态，计算公式如下：

$$K_k = \frac{P_k H^T}{HP_k H^T + R} \tag{3.3}$$

$$\hat{x}_k = x_k + K_k(Z_k - Hx_k) \tag{3.4}$$

$$P_k = (1 - K_k H)P_k \tag{3.5}$$

其中K_k为卡尔曼增益，R 是为传感器的噪声平均值，H 是变换矩阵的状态变量，Z_k为传感器测得的测量值，$\hat{x}_k$为后验估计即当前最优解。

在训练集的例子中，本章使用卡尔曼滤波算法对 iw 值进行平滑降噪处理，以提高数据的稳定性和可用性。对前 2000 条数据进行处理后的对比结果如图 3.3 所示。

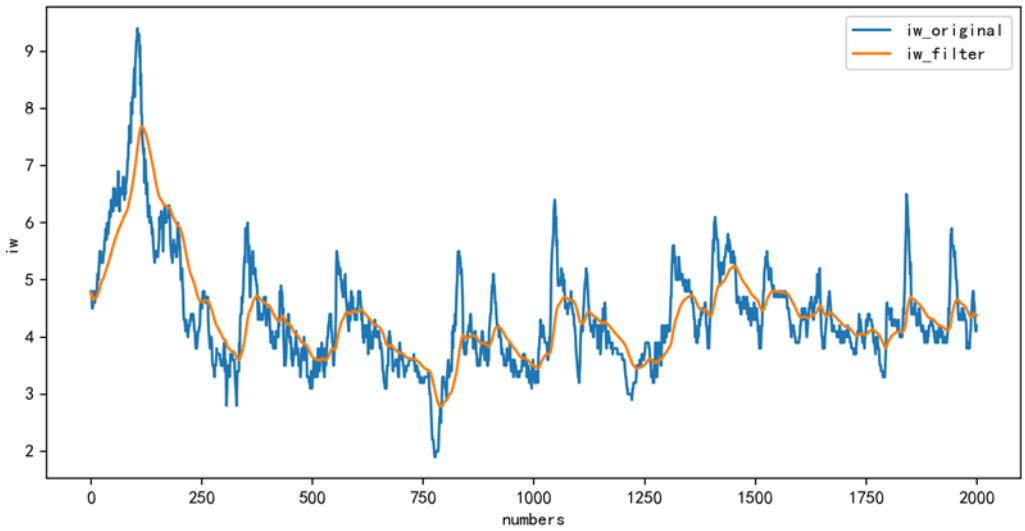

图 3.3 训练集 iw 原始值与滤波值对比图

图 3.3 中展示了原始 iw 值与经过卡尔曼滤波处理后的 iw 值的对比，通过观察图，可以清晰地看到平滑处理后的曲线相对于原始曲线更加平稳。卡尔曼滤波的作用在于有效地去除了 iw 值中的毛刺和噪声，使得数据更符合实际的变化趋势，有助于提高对血糖值的准确预测。

这种平滑降噪处理有助于模型更好地捕捉特征之间的关系，提高模型的泛化性能。通过在训练集上的应用，本章提出的这种处理方式能够在模型的训练和测试阶段带来更好的效果。这是确保血糖值预测模型更为可靠和稳健的一步。由于患者存在不易监测的高血糖和低血糖，

中国知网 https://www.cnki.net

本章在对信号使用卡尔曼滤波算法进行平滑降噪处理时要考虑参数的设置，使之平滑在合理的范围，不能过于平滑，以免影响高血糖或者低血糖值的预测。

（3）数据标准化

数据的标准化(normalization)是将数据缩放到更小的特定范围的过程。通过数据标准化可以加快数据的运算速度，并且有可能提高模型的预测精度。常见的数据标准化的方法包括：min-max 标准化[48](min-max normalization)，log 函数转换，atan 函数转换，z-score 标准化[49](zero-mena normalization)，模糊量化法。由于数据集中患者的血糖值波动范围较大,同时存在离群值的情况，因此在本章中选择使用 z-score 方法对所有数据归一化，其转化函数为：

$$z = \frac{x-\mu}{\sigma} \tag{3.6}$$

其中 μ 为均值，σ 为标准差，x、z 为归一化前后的数据。

3.3.3 粒子群优化基学习器

在 2022 年 5 月 24 日的 33 位患者的血糖数据中选取 27 位患者的数据作为训练集，用于模型的训练和超参数优化，同时剩余的 6 位患者数据中含真实血糖值的数据作为测试集，用于对调参后的模型进行评估。这样的划分方式旨在确保模型在训练阶段能够充分学习数据的模式和特征，而在测试阶段能够在未见过的数据上进行准确的预测。通过将真实血糖值的数据作为测试集，本章能够更客观地评估模型的性能，验证其在未知数据上的泛化能力。

在使用粒子群优化算法对模型进行超参数优化的过程中，首先选择了模型的平均绝对百分比误差作为粒子的适应度函数。这个适应度函数用于评估每个粒子（即模型超参数组合）在解空间中的性能，即其对训练数据的拟合程度。较低的平均绝对百分比误差值表示模型对实际数据的拟合效果更好。

其次，在初始化粒子群参数阶段，进行了随机初始化每个粒子的位置和速度。这代表了模型超参数的初始取值，是算法搜索的起点。随后，计算每个粒子的适应度，即根据当前参数组合评估模型的性能。

最后，通过比较每个粒子的适应度大小，判断每个粒子所在位置是否为当前最优值。如果是最优值，就替换原始位置的值，并更新每个粒子的位置和速度，以在解空间中寻找更优的模型超参数。这个过程通过迭代进行，直到达到设定的最大迭代次数为止。

值得注意的是，这里的粒子的位置实际上代表了模型超参数的取值。通过粒子群优化算法，系统在超参数空间中进行搜索，试图找到使适应度函数最小化（或最大化，根据具体问题而定）的最优解，即最适合数据的模型超参数组合。这一过程能够有效地帮助优化模型，

中国知网 https://www.cnki.net

提高其在未知数据上的性能。

在使用优化模型对测试集进行预测的过程中，模型超参数作为粒子的速度更新公式为：$v_{id}^{k+1} = \omega v_{id}^{k} + c_1 r_1 (p_{id,pbest}^{k} - x_{id}^{k}) + c_2 r_2 (p_{d,gbest}^{k} - x_{id}^{k})$，位置的更新公式为：$x_{id}^{k+1} = x_{id}^{k} + v_{id}^{k+1}$。其中设置粒子总数为 10、粒子维度为 2、迭代次数为 100、惯性权重为 0.5、学习因子 c1、c2 为 2。表 3.2 为 XGBoost、LightGBM 模型的主要参数及说明，另外对于 XGBoost、LightGBM 的超参数优化方案如表 3.3 所示。

表 3.2 XGBoost、Lightgbm 模型的主要参数及说明

参数名	含义	设定值
max_depth	树的最大深度	3
reg_lambda	L2 正则化项权重	1
learning_rate	学习率	0.1
n_estimators	迭代次数	100
num_leaves	树的叶子节点个数	20

表 3.3 XGBoost、LightGBM 模型超参数优化方案

超参数名	取值范围	速度取值范围
reg_lambda(XGBoost)	[2,8]	[0,1]
n_estimators(XGBoost)	[50,100]	[0,10]
num_leaves(LightGBM)	[2,15]	[0,1]
n_estimators(LightGBM)	[1,20]	[0,1]

3.3.4 stacking 模型融合

stacking 是一种特殊的层次结构，其中第一层是由不同的基学习器组成，而第二层以上的层次由前一层基学习器的输出作为输入，形成元学习器。为了防止过拟合，在 stacking 模型融合的基础上，本章提出在元学习器的训练过程中引入了重复 2 次的 5 折交叉验证，以有效避免过拟合问题。

具体而言，对于元学习器的训练，使用了 5 折交叉验证的方式，每次迭代中重复进行 2 次，这有助于更全面地利用数据集进行训练和验证。在每次迭代中，将数据集划分为 5 个互斥的子集，其中 4 个子集用于训练，而剩下的 1 个子集用于验证。重复进行 2 次这个过程，可以得到更加稳定和可靠的模型性能评估。

中国知网 https://www.cnki.net

这种交叉验证的引入有助于模型更好地泛化到未见过的数据，减少模型对训练数据的过度依赖，从而提高模型的鲁棒性。这是一种常见的策略，尤其在数据集相对较小或模型较为复杂时，通过交叉验证来防止过拟合问题是一种有效的方法。在这一框架下，stacking 模型得以更好地适应血糖值的精确预测任务。

为了提高血糖预测精度，结合 XGBoost、LightGBM 模型泛化能力强、运算效率高等优点，本章提出了基于粒子群优化和模型融合构建了血糖预测模型，第一层采用粒子群优化后的 XGBoost 模型和 LightGBM 模型，第二层采用弱学习器-贝叶斯回归模型。如图 3.4 所示为基于粒子群优化的融合模型的构建具体流程图。在第一层，通过粒子群优化算法分别对 XGBoost 和 LightGBM 模型进行了超参数优化，以确保它们在训练集上能够更好地拟合数据。这一层的目标是得到两个基学习器，它们在预测血糖值时具有优异的性能。在第二层，通过引入弱学习器贝叶斯回归模型，将第一层的输出结果进行融合。贝叶斯回归模型有助于综合利用不同模型的输出，从而提高整体模型的鲁棒性和泛化能力。这样的层次结构和融合策略旨在充分利用 XGBoost 和 LightGBM 的优势，同时通过粒子群优化来精细调整模型超参数。这个构建流程可以在血糖预测任务中取得更为准确和可靠的结果。

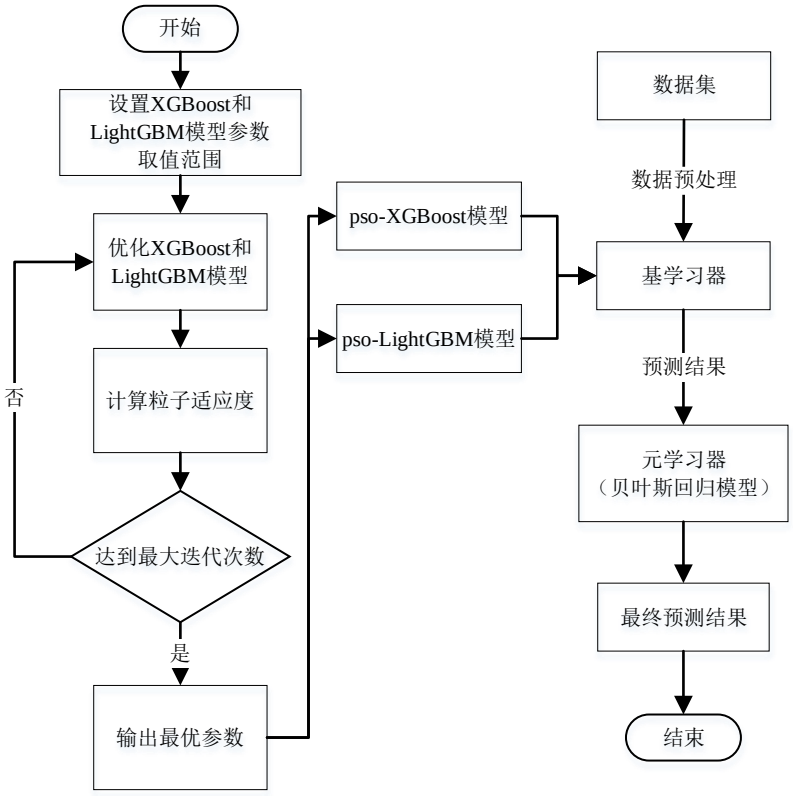

图 3.4 基于粒子群优化的融合模型的构建流程图

首先，本章将通过粒子群优化算法对 XGBoost 和 LightGBM 模型进行优化，将它们作为基学习器。接下来，将 3.3.2 节中处理好的样本数据输入到这两个基模型中，训练集包含 464,438 条数据，而测试集有 1,281 条数据。

中国知网 https://www.cnki.net

随后，本章采用 5 折交叉验证法对样本训练集进行处理，将其分割并输入至优化后的 XGBoost 模型中。在这里通过将训练集随机分成 5 份，其中 4 份用于模型训练，1 份用作验证集。在每次交叉验证过程中，每个子集都有机会作为验证集，从而可以得到近 92,888 条预测值，形成一个矩阵，其大小为 92,888 行 1 列。接下来，对测试集的 1,281 条数据进行预测，得到 1,281 条预测值，形成一个矩阵，大小为 1,281 行 1 列。最后，对 LightGBM 模型也采用相同的 5 折交叉验证法，得到对应的矩阵。

在完成 5 折交叉验证后，通过训练集 XGBoost 模型，可以得到一个包含 464,438 条预测数据的矩阵（记为 A1）。通过测试集 XGBoost 模型，可以得到一个包含 1,281 行 5 列预测数据的矩阵，对这些数据求均值得到一个包含 1,281 行 1 列的样本数据（记为 B1）。同样地，通过训练集 LightGBM 模型，可以得到一个包含 464,438 条预测数据的矩阵（记为 A2），通过测试集 LightGBM 模型，可以得到一个包含 1,281 行 5 列预测数据的矩阵，对这些数据求均值得到一个包含 1,281 行 1 列的样本数据（记为 B2）。

最后，将 A1 和 A2 两个矩阵作为特征，与训练集中的真实血糖值进行组合，形成第二层元学习器的训练集。同时，将 B1 和 B2 两个矩阵与测试集中的真实血糖值进行组合，形成第二层元学习器的测试集。随后，训练模型以预测血糖值，具体的步骤和原理可见于 2.2.3 节的 stacking 模型融合图。

3.4 实验结果及分析

3.4.1 实验环境

本章采用了一台配置为 Intel i5-7300 2.5GHz 四核四线程 CPU，拥有 16GB 内存的计算机。该计算机运行 Windows10 操作系统，而编程语言则选择了 Python。在编程环境方面，本章使用了 PyCharm 作为开发工具。为了实现算法和模型的开发，本章采用了 Python 库，其中包括了 NumPy、Scikit-learn、Pandas、XGBoost、LightGBM 等。

这样的配置和工具选择确保了有足够的计算能力和便捷的开发环境，使得在处理大规模数据和进行机器学习模型训练时能够高效而稳定地完成任务。借助这些工具，开发人员能够充分发挥计算机性能，提高开发效率，并在实验过程中灵活地处理数据和调整模型参数。

3.4.2 模型评价指标

本章选择了平均绝对百分比误差(Mean Absolute Percentage Error, MAPE)和均方根误差

中国知网 https://www.cnki.net

(Root Mean Squared Error, RMSE)两个评价指标来评估模型的性能。这两个指标是用于衡量预测性能的常用工具，具有直观的解释和广泛的适用性。MAPE 是用于评估预测性能的最受欢迎的指标之一，它是衡量预测误差的一种百分比指标，计算方式为实际值与预测值之间的绝对百分比误差的平均值。RMSE 通常被用作衡量机器学习模型预测结果的标准，它度量了预测值与实际值之间的差异，计算方式为预测误差的平方的均值再开平方。这两个指标的数值越小，说明模型的血糖值预测准确率越高。通过综合考虑这两个评价指标，可以更全面地评估模型在血糖值预测任务中的性能表现。它们具体的评价函数公式如下：

$$\mathrm{MAPE} = \frac{1}{N}\sum_{i=1}^{N}\frac{|\hat{y}_i - y_i|}{y_i} \times 100\% \tag{3.7}$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2} \tag{3.8}$$

其中 N 为样本个数，$\hat{y}_i$为预测血糖值，y_i为真实血糖值。

3.4.3 滤波结果分析及对比

卡尔曼滤波算法在对系统下一步的走向进行有根据的预测方面具有出色的性能，即使在存在各种干扰的情况下，卡尔曼滤波也能够准确指示真实发生的情况。在连续变化的系统中应用卡尔曼滤波被认为是非常理想的选择。本章选择使用卡尔曼滤波算法的主要目的之一是减少传感器信号噪音对血糖预测结果的影响，如表 3.4 所示。

表 3.4 卡尔曼滤波结果

模型	MAPE(%)	RMSE(mg/dL)
XGBoost	16.00	27.56
LightGBM	16.12	27.78
KF-XGBoost	14.77	24.44
KF-LightGBM	15.08	26.08

从表 3.4 的结果可以观察到，在使用卡尔曼滤波算法对原始数据进行平滑降噪处理后，血糖的预测误差显著降低。具体而言，在 MAPE 指标上，KF-XGBoost 的预测误差比 XGBoost 降低了 1.23%，而 KF-LightGBM 的预测误差比 LightGBM 降低了 1.04%。在 RMSE 指标上，KF-XGBoost 的预测误差比 XGBoost 降低了 3.12mg/dL，KF-LightGBM 的预测误差比 LightGBM 降低了 1.7mg/dL。

表 3.5 是分别采用自适应滤波器、滑动窗口滤波器和卡尔曼滤波算法对原始数据进行平滑降噪处理后的预测结果。从表 3.5 的结果可以观察到，使用卡尔曼滤波算法后的预测结果明显优于自适应滤波器和滑动窗口滤波器。具体而言，在 MAPE 指标上，KF-XGBoost 的预

中国知网 https://www.cnki.net

测误差比 AF-XGBoost 降低了 1.14%，比 MWF-XGBoost 降低了 1.43%，而 KF-LightGBM 的预测误差比 AF-LightGBM 降低了 0.65%，比 MWF-LightGBM 降低了 0.91%。在 RMSE 指标上，KF-XGBoost 的预测误差比 AF-XGBoost 降低了 2.65mg/dL，比 MWF-XGBoost 降低了 2.69mg/dL，而 KF-LightGBM 的预测误差比 AF-LightGBM 降低了 1.22mg/dL，比 MWF-LightGBM 降低了 1.71mg/dL。

表 3.5 不同滤波算法结果对比

模型	MAPE(%)	RMSE(mg/dL)
AF-XGBoost	15.91	27.09
MWF-XGBoost	16.20	27.13
KF-XGBoost	14.77	24.44
AF-LightGBM	15.73	27.30
MWF-LightGBM	15.99	27.79
KF-LightGBM	15.08	26.08

这些结果表明，卡尔曼滤波算法的应用对于减少血糖预测模型的误差具有显著的优势。通过对传感器信号进行平滑处理，卡尔曼滤波能够有效抑制噪音，提高模型对血糖值的准确性预测。在 MAPE 和 RMSE 两个指标上的降低表明卡尔曼滤波在改善模型性能方面的有效性。因此，卡尔曼滤波算法在提高血糖预测模型的稳健性和鲁棒性方面发挥了积极的作用。这是一个有力的工具，能够在处理传感器数据时有效地提高模型的预测性能，具有一定的优越性。

3.4.4 优化结果分析及对比

图 3.5 展示了粒子群优化算法在对 XGBoost 模型超参数进行优化时，适应度值随着 pso 迭代次数的变化曲线。同样，图 3.6 则展示了在对 LightGBM 模型超参数进行优化时，适应度值随 pso 迭代次数的变化曲线。从这两个图中可以观察到，在 XGBoost 模型超参数优化的过程中，当迭代次数达到约 10 次时，就能够搜索到模型的最优超参数组合。而在 LightGBM 模型超参数优化的过程中，需要迭代次数约为 20 次，才能够搜寻到最优的参数组合。这说明粒子群优化算法在相对较少的迭代次数内，就能够有效地搜索到 XGBoost 和 LightGBM 模型的最优超参数组合。这种高效的搜索特性有助于在有限的时间内找到适合模型的超参数配置，从而提高模型的性能。这样的结果为模型的精细调参提供了有力的支持，确保在建立血糖预测模型时选择到最优的超参数组合。

中国知网 https://www.cnki.net

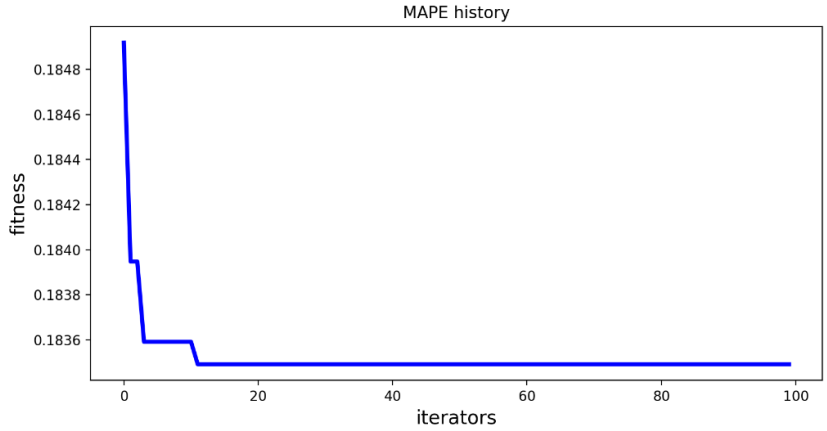

图 3.5 PSO-XGBoost 超参数迭代曲线

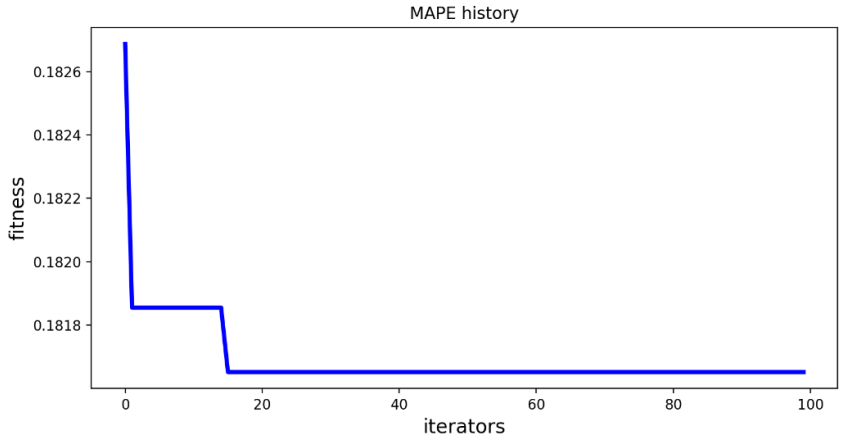

图 3.6 PSO-LightGBM 超参数迭代曲线

在设定的终止迭代条件下，利用 PSO 优化结果见表 3.6。

表 3.6 PSO 优化结果

超参数名	设定值
reg_lambda(XGBoost)	4
n_estimators(XGBoost)	52
num_leaves(LightGBM)	14
n_estimators(LightGBM)	20

根据数据集，使用优化后的超参数对模型进行训练，预测结果如表 3.7 所示。

表 3.7 PSO 优化结果对比

模型	MAPE(%)	RMSE(mg/dL)
XGBoost	14.77	24.44
LightGBM	15.08	26.08
PSO-XGBoost	13.85	22.91
PSO-LightGBM	14.07	21.54

从表 3.7 的结果可以看出，在使用粒子群优化算法对模型进行超参数优化后，血糖的预

中国知网 https://www.cnki.net

测误差明显降低。具体而言，在 MAPE 指标上，PSO-XGBoost 的预测误差比 XGBoost 降低了 0.92%，而 PSO-LightGBM 的预测误差比 LightGBM 降低了 1.01%。在 RMSE 指标上，PSO-XGBoost 的预测误差比 XGBoost 降低了 1.53mg/dL，PSO-LightGBM 的预测误差比 LightGBM 降低了 4.54mg/dL。

表 3.8 不同优化算法结果对比

模型	MAPE(%)	RMSE(mg/dL)
PSO-XGBoost	13.85	22.91
Bay-XGBoost	14.31	23.42
TPOT-XGBoost	13.96	22.84
PSO-LightGBM	14.07	21.54
Bay-LightGBM	14.69	22.04
TPOT-LightGBM	14.26	21.52

表 3.8 是采用粒子群优化算法、贝叶斯优化算法和自动化工具 TPOT 对 XGBoost 和 LightGBM 模型进行超参数优化后的预测结果对比。从表 3.8 中可以看出，粒子群优化算法优化结果优于贝叶斯优化和自动化工具 TOPT。具体而言，在 MAPE 指标上，PSO-XGBoost 的预测误差比 Bay-XGBoost 降低了 0.46%，比 TPOT-XGBoost 降低了 0.11%，PSO-LightGBM 的预测误差比 Bay-LightGBM 降低了 0.62%，比 TPOT-LightGBM 降低了 0.19%。在 RMSE 指标上，PSO-XGBoost 的预测误差比 Bay-XGBoost 降低了 0.51mg/dL，比 TPOT-XGBoost 升高了 0.07mg/dL，PSO-LightGBM 的预测误差比 Bay-LightGBM 降低了 0.50mg/dL，比 TPOT-LightGBM 升高了 0.02mg/dL。

这些结果表明，粒子群优化算法在超参数优化方面的应用具有一定的优越性。通过对模型超参数进行更精细的调整，粒子群优化有助于提高模型的性能，减少对血糖预测的误差。在 MAPE 和 RMSE 两个指标上的降低表明粒子群优化在改善模型性能方面是有效的。

因此，粒子群优化算法在调整模型超参数时发挥了积极的作用，为建立更准确的血糖预测模型提供有力的支持。这是一种有效的优化手段，能够在有限的时间内找到更适合模型的超参数配置。

3.4.5 模型融合结果分析及对比

本章的方法包括将第一层优化后的 XGBoost 和 LightGBM 模型的输出结果输入到第二层的贝叶斯回归模型中，以此来预测血糖值。预测结果如表 3.9 所示。为了更全面地验证模型的

中国知网 https://www.cnki.net

效果，本章将 XGBoost、LightGBM、CatBoost、贝叶斯回归、线性回归、以及凯立特算法进行了对比。通过计算平均绝对百分比误差(MAPE)和均方根误差(RMSE)这两个指标来评估各个模型的效果。这种层次结构的模型融合方法，将不同模型的输出结果通过贝叶斯回归模型进行集成，有望获得更为准确和稳健的血糖值预测。表 3.9 中的结果将提供对各个模型性能的直观比较，有助于确定哪个模型在血糖预测任务中表现最佳。通过计算 MAPE 和 RMSE，可以更全面地评估各个模型在不同衡量标准下的性能表现，从而为模型选择和优化提供指导。这种综合比较有助于确定最适合解决特定问题的模型，并为进一步研究提供基础。

表 3.9 各个模型的预测结果对比

模型	MAPE(%)	RMSE(mg/dL)
XGBoost	14.77	24.44
LightGBM	15.08	26.08
CatBoost	14.44	24.35
线性回归	15.09	24.08
贝叶斯回归	15.09	24.08
凯立特算法	18.05	27.92
stacking 融合模型	13.01	23.15

从表 3.9 中可以观察到，相较于基学习器、CatBoost、线性回归、贝叶斯回归和凯立特算法，本章提出的基于粒子群优化和模型融合的血糖预测方法在预测性能上具有显著的优势。在 MAPE 指标上，预测效果比基学习器提高了 1.76%和 2.07%，而相较于凯立特算法更是提高了 5.04%。在 RMSE 指标上，预测效果比基学习器提高了 1.29mg/dL 和 2.93mg/dL，比凯立特算法提高了 4.77mg/dL。

从这两个指标的比较中可以得出，本章提出的血糖预测方法在预测效果和泛化能力方面都远远超过了 CatBoost、线性回归、贝叶斯回归和凯立特算法。这表明通过粒子群优化和层次结构的模型融合，能够更有效地捕捉数据的特征，提高模型的预测精度。

因此，本章提出的血糖预测方法在不同评价标准下都取得了显著的优越性，为血糖值的准确预测提供了一种强大而可行的方法。这种综合的模型设计和优化策略使得模型在实际应用中更具可信度和实用性。

图 3.7 展示了基学习器和融合方法对患者血糖值的预测结果。通过观察图 3.7，可以发现本章提出的融合方法在预测结果上表现最佳，而 LightGBM 模型的预测结果较差，XGBoost 模型的预测结果介于两者之间。综合考虑表 3.9 中的评价指标，融合方法的 MAPE 为 13.01%、RMSE 为 23.15mg/dL，XGBoost 模型的 MAPE 为 14.77%、RMSE 为 24.44mg/dL，LightGBM

中国知网 https://www.cnki.net

模型的 MAPE 为 15.08%、RMSE 为 26.08mg/dL。从这些评价指标的数值上看，本章提出的融合方法在 MAPE 和 RMSE 两个方面的值都最小，说明其预测准确率最高。这与图 3.7 中的预测结果一致，表明融合方法在对患者血糖值进行预测时能够取得最佳的效果。这也进一步验证了粒子群优化和模型融合策略在提高模型性能方面的有效性。

因此，通过综合考虑图 3.7 的可视化结果和表 3.9 中的评价指标，可以得出本章提出的基于粒子群优化和模型融合的血糖预测方法在实际预测任务中取得了显著的优势。

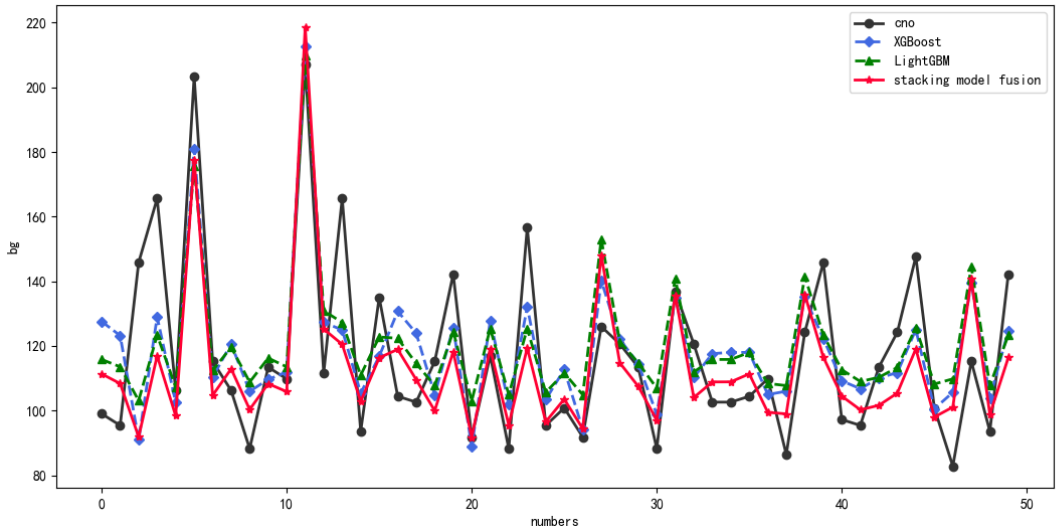

图 3.7 模型预测结果对比图

图 3.8 展示了 CatBoost、线性回归、贝叶斯回归、凯立特算法和融合方法对患者血糖值的预测结果。通过观察图 3.8，可以得知本章提出的融合方法在预测结果上表现最佳，CatBoost 模型的预测效果次之，凯立特算法的预测效果最差，而线性回归与贝叶斯回归的预测结果介于它们之间。综合考虑表 3.9 中的评价指标，融合方法的 MAPE 为 13.01%、RMSE 为 23.15mg/dL，CatBoost 模型的 MAPE 为 14.44%、RMSE 为 24.35mg/dL，凯立特算法的 MAPE 为 18.05%、RMSE 为 27.92mg/dL，线性回归与贝叶斯回归的 MAPE 为 15.09%、RMSE 为 24.08mg/dL。

从这些评价指标的数值上看，融合方法在 MAPE 和 RMSE 两个方面的值都最小，说明其预测准确率最高。这与图 3.8 中的预测结果一致，表明融合方法在对患者血糖值进行预测时能够取得最佳的效果。这也再次验证了粒子群优化和模型融合策略在提高模型性能方面的有效性。因此，通过综合考虑图 3.8 的可视化结果和表 3.9 中的评价指标，可以得出本章提出的基于粒子群优化和模型融合的血糖预测方法在与其他模型的比较中仍然表现出色，显示了其在实际预测任务中的显著优势。

总的来说，图 3.7 和图 3.8 展示了各个模型对测试集中前 50 条患者血糖的预测结果与真实血糖值的对比。通过观察这些图表，可以得出以下结论：与 XGBoost、LightGBM、CatBoost、贝叶斯回归、线性回归、凯立特算法相比，stacking 融合模型的预测结果在大多数情况下都非

中国知网 https://www.cnki.net

常接近真实的血糖值，其拟合程度更高，预测效果更好。、

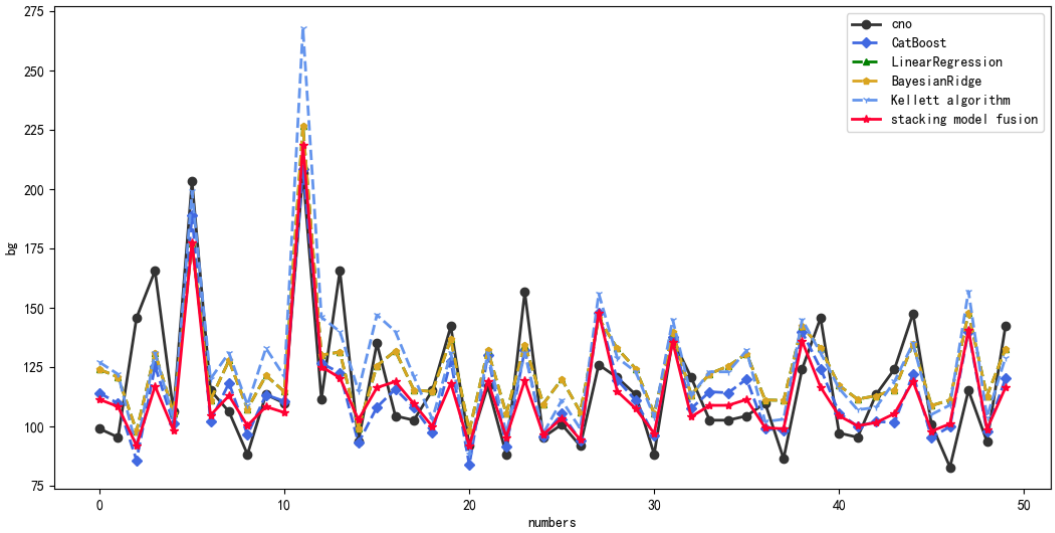

图 3.8 模型预测结果对比图

从图中的可视化效果可以看出，本章提出的基于粒子群优化和融合模型的血糖预测方法在模型对患者血糖值的拟合方面表现出色。预测结果在大多数情况下与真实血糖值非常接近，呈现出更高的拟合程度。这进一步证实了通过粒子群优化和层次结构的模型融合能够显著提高血糖预测的准确性和泛化能力。因此，综合图 3.7 和图 3.8 的观察结果，可以得出本章提出的基于粒子群优化和融合模型的血糖预测方法在实际应用中具有一定的优越性，能够更准确地预测患者的血糖值。

表 3.10 10 位患者血糖预测结果(MAPE)

患者编号	stacking fusion model	XGBoost model
1	13.66	15.17
2	12.19	13.13
3	15.01	16.5
4	11.23	12.22
5	9.68	11.13
6	19.51	20.64
7	10.89	16.31
8	18.09	18.83
9	8.35	10.28
10	10.04	11.24

由表 3.9 的结果来看，XGBoost 模型的预测误差和本文的预测方法较为接近。为了更好地展现对比结果，下面将预测结果按照患者进行细分。表 3.10 和图 3.9 是本文提出的基于粒

中国知网 https://www.cnki.net

子群优化和模型融合的血糖预测方法和 XGBoost 模型对 10 位患者血糖预测的平均绝对百分比误差的对比结果。

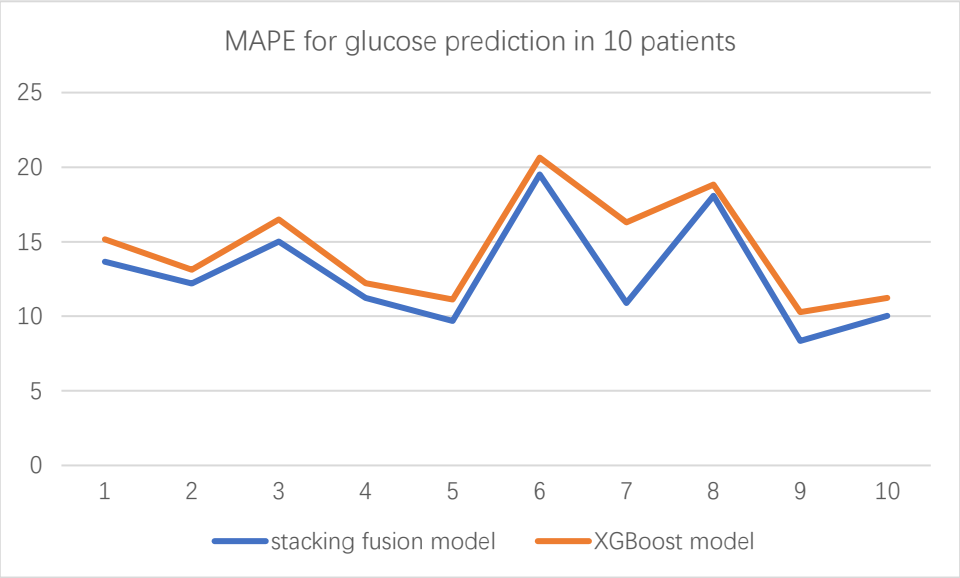

图 3.9 10 位患者的血糖预测的 MAPE

由表 3.10 和图 3.9 可以看出，在对 10 位患者的血糖预测效果上，本文提出的方法都优于 XGBoost 模型，误差比 XGBoost 模型都低 1%~2%之间。尤其对 7 号患者的血糖预测，两者拉开了较大的差距。由此可见，本文提出的方法比 XGBoost 模型预测更准确，泛化能力更强，在预测全新患者的血糖水平上具有一定的优越性。

在 stacking 模型融合的过程中，第一层模型的选择至关重要。通常，开发人员会选择性能较强、有差异度的算法作为基学习器，以确保各模型之间存在显著的差异性，从而增强整体融合效果。这种策略使得 stacking 能够更好地适应复杂的数据结构和模式。因此，基学习器的组合在 stacking 中扮演着至关重要的角色，不同的基学习器组合将直接影响整体模型的性能和泛化能力。通过选择性能较强、有显著差异度的基学习器，可以实现更为有效的融合效果。

表 3.11 不同融合模型的预测结果对比

模型组合	MAPE(%)	RMSE(mg/dL)
XGBoost+CatBoost//Bayesian	13.69	23.75
LightGBM+CatBoost//Bayesian	13.25	23.29
XGBoost+LightGBM+CatBoost// Bayesian	13.24	23.29
stacking 融合模型	13.01	23.15

表 3.11 展示了不同基学习器融合的预测结果对比。通过比较这些结果，可以得出关于基学习器组合效果的结论。在选择第一层模型时，性能较强、具有差异性的算法组合是关键，因为它们能够捕捉数据中的不同特征和模式，为整体模型提供更多信息，提高预测性能。因

中国知网 https://www.cnki.net

此，在 stacking 模型的设计中，基学习器的选择需要经过慎重考虑，以确保不同模型之间的差异性。这有助于提高整体模型的鲁棒性和泛化能力，使其更好地适应不同的数据结构和模式。表 3.11 的对比结果提供了在不同基学习器组合下的预测效果，为选择适当的模型组合提供了有益的参考。

从表 3.11 可以看出，本章提出的 stacking 融合模型(XGBoost+LightGBM//Bayesian)在预测效果上表现最优。具体而言，在 MAPE 指标上，XGBoost 和 LightGBM 的组合相较于 XGBoost 和 CatBoost 的组合降低了 0.68%，相较于 LightGBM 和 CatBoost 的组合降低了 0.24%，相较于 XGBoost、LightGBM 和 CatBoost 的组合降低了 0.23%。在 RMSE 指标上，XGBoost 和 LightGBM 的组合相较于 XGBoost 和 CatBoost 的组合降低了 0.6mg/dL，相较于 LightGBM 和 CatBoost 的组合降低了 0.14mg/dL，相较于 XGBoost、LightGBM 和 CatBoost 的组合降低了 0.14mg/dL。

这些比较结果表明，本章提出的 stacking 融合模型在不同组合下都表现出色，尤其在 MAPE 和 RMSE 两个指标上相对其他组合取得了更佳的效果。这再次验证了通过选择性能较强、有显著差异度的基学习器组合，可以实现更为有效的融合效果。在实际应用中，选择合适的基学习器组合对于 stacking 模型的性能至关重要。

表 3.12 是不同融合模型训练时间消耗的对比。从表中可以看出，本章提出的 stacking 融合模型(XGBoost+LightGBM//Bayesian)训练的时间最短，比 XGBoost 和 CatBoost 的组合少 64.889 秒，比 LightGBM 和 CatBoost 的组合少 50.952 秒，比 XGBoost、LightGBM 和 CatBoost 的组合少 70.845 秒。

表 3.12 不同融合模型训练时间消耗对比

模型组合	时间（s）
XGBoost+CatBoost//Bayesian	88.779
LightGBM+CatBoost//Bayesian	74.842
XGBoost+LightGBM+CatBoost// Bayesian	94.735
stacking 融合模型	23.890

综合表 3.11 和表 3.12 的结果，不难看出，本章提出的融合模型的血糖预测方法无论从预测误差的角度，还是从模型训练时间消耗的角度来看，都表现优异。stacking 融合模型在预测效果上取得了更佳的结果，同时在训练时间上也更为高效。这再一次证明了本章提出的基于粒子群优化和融合模型的血糖预测方法在实际应用中具有一定的优越性。

综上所述，通过对不同融合模型的比较分析，本章提出的基于粒子群优化和融合模型的血糖预测方法在预测准确性和模型训练效率方面均表现出色，为血糖预测任务提供了一种可

中国知网 https://www.cnki.net

行且高效的解决方案。

3.5 本章小结

本章提出的基于模型融合的血糖预测模型，该模型先是通过卡尔曼滤波算法和 z-score 方法对传感器数据进行预处理，再利用粒子群优化算法对 XGBoost 和 LightGBM 模型进行超参数优化。最后，以优化后的 XGBoost 和 LightGBM 模型为基学习器，结合贝叶斯回归模型作为元学习器，对传感器数据进行训练和测试，实现对血糖值的较为准确的预测。通过实验对比的结果显示，本章提出的基于模型融合的血糖预测模型在预测效果上明显优于单一的基学习器，取得了 1.76%和 2.07%的预测精度提升。相较于其他回归模型和不同的组合模型，该融合模型也展现出更高的预测精度。这说明了通过结合不同模型和优化方法，可以显著提升血糖预测的准确性，为血糖值预测提供了一种可行而高效的解决方案。

中国知网 https://www.cnki.net

第四章　基于增量学习的血糖预测实时更新模型

人工智能和机器学习的进步推动了众多算法的开发，其中大多数采用批量学习模式。在批量学习中，假设可以一次性获取所有训练样本，在学习完这些样本后停止学习，不再更新知识。然而，实际应用中，训练样本无法一次性获取，而是随时间逐步积累，样本信息也可能随时间变化。如果每次新样本到达都需要重新学习全部数据，将耗费大量时间和空间。因此，批量学习算法难以满足这种需求。本章基于不同型号的血糖仪数据，提出一种基于增量学习的血糖预测实时更新模型。该方法首先通过异常值检测和信号分解算法对血糖原始信号进行分解，提取不同时间尺度的局部特征信息，以降低血糖预测误差。然后基于 XGBoost 和 LightGBM 增量学习方法，每当新增数据时，并不需要重新训练模型，而是在原有的知识库的基础上，仅根据新增数据所引起的变化对模型实时更新。

4.1 研究背景

传统的机器学习算法大多属于批处理学习模式，即假设在训练前可以一次性获得所有的训练样本。在学习完这些样本后，学习过程停止，不再学习新的知识。然而，在实际应用中，通常不可能一次获得所有的训练样本，而是随着时间的推移逐渐获得，并且样本所反映的信息也可能随着时间的推移而变化。如果一个新的样本到来，需要重新学习所有的数据，这需要大量的时间和空间，所以批处理学习算法不满足这一要求。只有增量学习才能逐步更新知识，纠正和增强以前的知识，使更新的知识能够适应到达的数据，而不需要重新学习所有的数据。增量学习减少了对时间和空间的需求，更符合实际需求。

增量学习的思想可以描述为:每当增加新的数据时，不需要重建所有的知识库，而只需要在原有知识库的基础上更新新数据引起的变化。增量学习有很多框架，每个框架的核心内容都是处理新数据与存储知识之间的相似性评价方法。因此，这种方法决定了感知新知识和增加知识库的方式，影响了知识的增长。新知识的判断机制才是增量学习的核心部件。

本文在第三章提出了一种基于模型融合的血糖预测方法，但是该方法在训练过程中会耗费相当多的时间，如果新型号血糖仪的数据与旧的相差较大，就需要重新训练。基于此，本章提出一种基于增量学习的血糖预测实时更新模型。该方法主要通过异常值检测和信号分解算法对血糖原始信号进行分解，提取不同时间尺度的局部特征信息，以降低血糖预测误差。然后基于 XGBoost 和 LightGBM 增量学习方法，每当新增数据时，并不需要重新训练模型，

中国知网　https://www.cnki.net

而是在原有的知识库的基础上，仅根据新增数据所引起的变化对模型实时更新。下面将从融合模型的总体设计、构建两个方面进行详细介绍。

4.2 实时更新模型的总体设计

本章首先对不同型号的血糖仪数据进行了详尽的数据预处理，后针对其中的工作电流信号进行了信号分解实验，以更好地理解并挖掘数据中蕴含的信息。最后基于第三章提出的 XGBoost 和 LightGBM 模型，使用增量学习方法训练出实时更新模型，实现对新数据的准确预测。为了清晰展现基于增量学习的血糖预测实时更新模型的基本流程，在图 4.1 中呈现了该流程的关键步骤和交互过程。这一流程不仅仅是模型训练的过程，更是一个持续学习和适应新数据的动态系统，确保模型能够保持高准确性并实现实时性的预测。

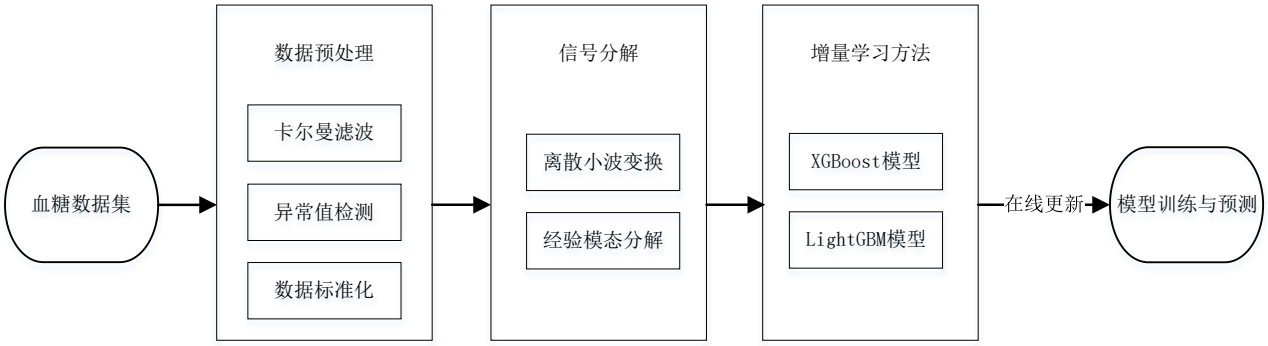

图 4.1 实时更新模型总体流程

从图 4.1 中可以看出，第一步是对血糖数据集进行了详细的预处理。在这一步骤中，引入了卡尔曼滤波算法对电流信号进行平滑降噪处理，以提高数据的质量和可解释性，随后使用异常值检测算法对数据进行筛选，去除可能对模型训练产生影响的异常值。最后对血糖数据进行标准化处理，为后期模型训练做好准备。

第二步是使用两种不同的信号分解算法：离散小波变换和经验模态分解，这些算法被用于对工作电流信号进行分解，从而提取出信号重要特征信息，这一过程的目标是降低血糖预测误差，确保模型更加准确和可靠。通过对比实验结果，本章选择出最为适用的分解算法，为进一步的建模工作提供指导。

最后一步是基于 XGBoost 和 LightGBM 模型，使用不同的增量学习方法训练出实时更新模型，这些模型在持续学习的过程中能够适应新的数据，确保模型的鲁棒性和性能持续优化。最后使用标准化后的数据对实时更新模型进行训练，以实现对血糖值的准确预测。

总的来说，这个研究框架综合运用了信号处理、异常值检测、分解算法和增量学习等多种技术手段，旨在建立一个高效且适应性强的血糖值预测实时更新模型。考虑到第三章

中国知网 https://www.cnki.net

stacking 模型融合的时间消耗，可能会影响实时更新的效率，故只基于基模型实现增量学习。另外，引入信号处理部分是为了实现减少模型训练时间的同时，提高预测精度。通过这一流程，本文致力于提高预测的实时性和准确性，从而为血糖管理提供更为可靠的支持。

4.3 实时更新模型的构建

4.3.1 数据来源

本章所用的数据是不同型号的血糖仪生成的 2022 年 5 月 24 日 33 位患者和 2022 年 6 月 16 日 10 位患者的血糖数据。其中，5 月 24 日的数据作为训练集训练出初步的模型，6 月 16 日的数据作为测试集，另外针对增量学习选择其中 3 位患者的数据作为初步模型的增量训练，剩下的 7 位患者的数据作为实时更新模型的测试集。

4.3.2 异常值检测

在传感器信号采集过程中，可能会受到外界因素的干扰，如传感器脱出、胶布松动、防水失效、外膜破损等情况，这些因素可能导致数据采集异常。然而，许多机器学习算法在存在异常值的情况下表现不佳，因此需要引入异常检测技术以应对这种情况。

异常检测是一种数据分析技术，用于识别数据集中与大多数数据明显不同的数据点，这些不同可能是由于错误、故障、欺诈、安全威胁或其他异常原因引起的。异常或异常值，也称为离群点(Outliers)或奇异点(Anomalies)，是数据中与大多数其他数据点不同的观测结果，它们偏离大多数对象，就好像是由不同的机制生成的。在异常值检测领域，有许多算法可供选择，每种算法都有其适用的场景和优势。

在本章中，最终决定采用箱线图法作为异常检测的方法。箱线图法通过观察数据的分布情况，识别出落在数据分布边缘之外的异常值。这种方法不仅简单而且直观，而且在实际应用中被广泛证明有效。通过选择适当的异常检测方法能够提高数据质量，确保在处理传感器数据时更加可靠和稳健。

箱线图(Boxplot)，也被称为箱须图(Box-whisker Plot)[50]，是一种通过使用数据中的五个统计量（最小值、第一四分位数、中位数、第三四分位数与最大值）来描述数据分布的方法。其原理如图 4.2 所示，通过对数值型数据进行图形化描述，箱线图将数据的上下边界以分位数表示，形成了箱体，同时通过触线(whisker)延伸出来，表示数据的整体分布。

在箱线图中，任何出现在下须触线下面或上须触线上面的数据点都被视为异常值。这种

中国知网 https://www.cnki.net

直观的图形表示方式能够快速而准确地识别数据集中的异常情况。通过采用箱线图法进行异常值检测，本章可以在传感器数据中迅速发现可能由于外界因素引起的异常值，从而采取相应的处理措施，确保数据的可靠性和准确性。

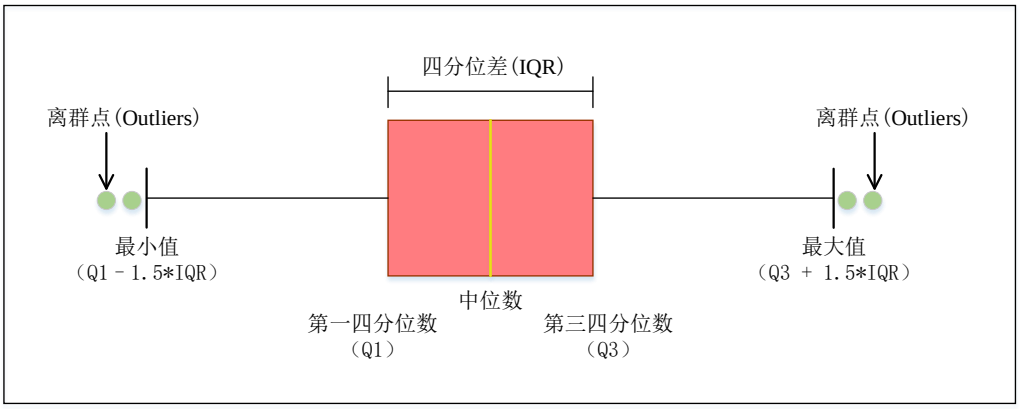

图 4.2 箱线图原理

4.3.3 信号分解实验

（1）离散小波变换

离散小波变换是一种同时在时域和频域进行变换的方法，其主要特点是可以将一段连续时间的信号分解成多个不同频率的小波子带，从而更准确地描述信号的特征。相较于其他变换方法，离散小波变换具有更好的时间-频率局部化性质，因此能够更好地适应非平稳信号的处理需求。考虑到传感器电流信号往往呈现非线性和非平稳的特性，采用离散小波变换对其进行分解具有显著的优势。这种变换方法能够有效地分解信号，将其表示为多个频率成分，使得人们能够更好地理解和处理信号的动态特性。通过得到线性平稳的小波分量，本章可以在处理这些分量时提高模型的预测精度，从而更准确地预测传感器电流信号的行为，以更深入、更全面地挖掘和利用传感器数据中潜在的信息。

在广泛的信号处理应用中，Daubechies 小波函数占据着重要的地位，其灵活性和多功能性使其成为信号处理领域的关键工具。以信号去噪为例，Daubechies 小波函数通过巧妙的信号分解，能够有效去除高频噪声，使得处理后的信号更为清晰和可靠。在信号压缩方面，通过分解信号并保留关键的低频分量，Daubechies 小波函数实现了对信号的紧凑压缩，节省了存储和传输资源。此外，Daubechies 小波函数在信号特征提取方面也表现出色。通过深入分析信号的局部特征，这些小波函数能够精准提取信号中的重要特征，为后续的信号分类、识别等任务提供了可靠基础。总体而言，Daubechies 小波函数的多功能性使其成为信号处理中不可或缺的工具，为各种应用场景提供了信号分析和处理能力。

在对传感器电流信号进行平滑和异常检测后，本节采用了离散小波变换对数据集进行分

中国知网 https://www.cnki.net

解。选择的小波基函数为 Daubechie3(db3)，即长度为 3 的 Daubechie 小波，分解层数为 3 层。分解的结果如图 4.3 所示。观察图 4.3 可以发现，通过使用 DWT 和 db3 小波，电流信号成功分解为近似系数 A3 以及细节系数 D3、D2 和 D1。这种分解能够有效地将原始信号在不同频率层次上进行拆分，使得我们能够更清晰地了解信号的频域特性。具体而言，近似系数 A3 捕捉到信号的大致趋势，而细节系数 D3、D2 和 D1 则表示不同频率范围内的细节信息。这有助于本章更深入地分析和理解电流信号的结构，为后续的分析和建模提供了更多的信息基础。图 4.3 的结果展示了 DWT 和 Daubechie 小波的有效性，为信号处理的进一步步骤奠定了技术实现基础。

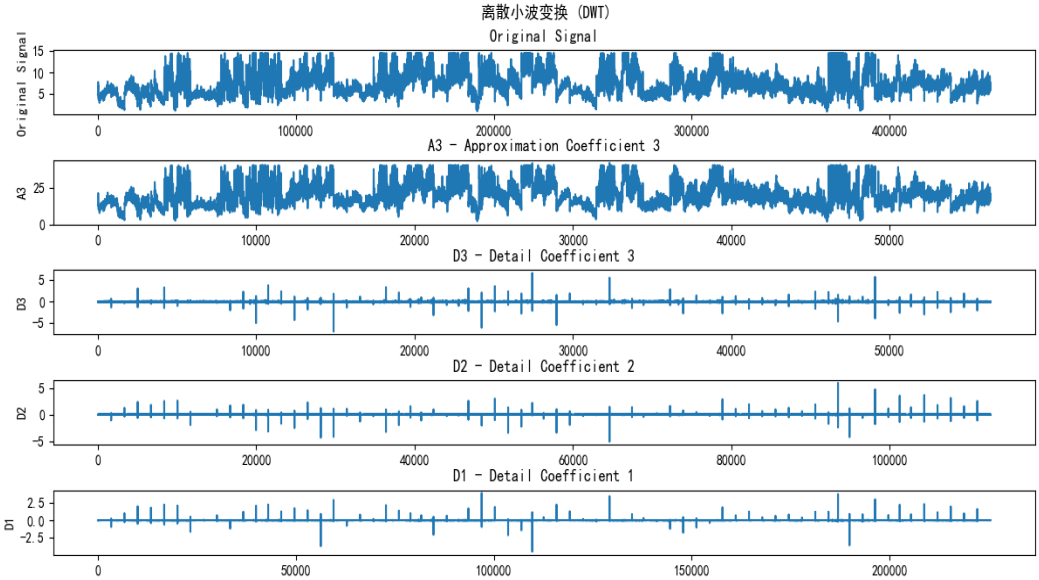

图 4.3 小波分解三层

（2）经验模态分解

经验模态分解(EMD)是一种基于数据本身时间尺度特征的信号分解方法。它的独特之处在于不需要事先设置任何基函数，属于时频域信号处理方法。EMD 在处理非平稳和非线性数据方面显示出明显的优势，特别适合分析具有非线性和非平稳特性的信号序列，并且具有较高的信噪比。该方法的关键在于经验模态分解，它将复杂信号分解为有限个本征模态函数(IMF)和残差分量(Residue)。

在 EMD 的过程中，信号通过一系列迭代得到 IMF 分量，每个 IMF 都代表了原信号在不同时间尺度上的局部特征信息。这种分解方式允许人们更细致地观察信号中的局部结构，使得分析结果更加具有解释性和可解释性。最终得到的 IMF 分量和残差分量的组合能够还原原始信号，但每个 IMF 都包含了不同时间尺度上的信号成分。总体而言，EMD 作为一种自适应且非参数的信号分解方法，为处理复杂信号提供了强大的工具，特别适用于对非线性非平稳

中国知网 https://www.cnki.net

信号的深入分析和建模。

在对传感器电流信号进行平滑和异常检测后，本节采用了经验模态分解作为信号处理的进一步步骤。经验模态分解的独特之处在于分解过程无需考虑基函数的选择，而是根据数据自身的时间尺度特征进行分解，因此可以直接使用。

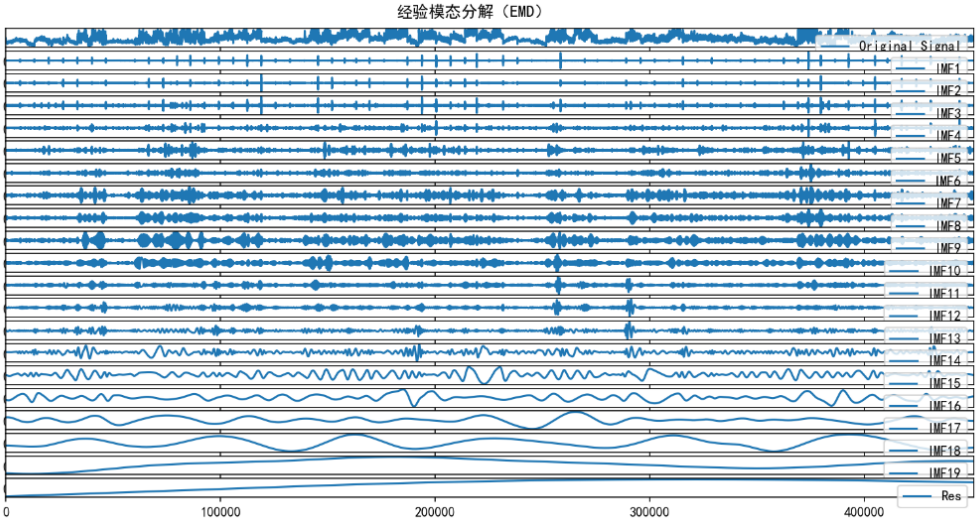

图 4.4 EMD 分解结果

图 4.4 展示了对传感器原始信号进行经验模态分解的结果。EMD 表现出色的自适应性使得本章能够将原始信号分解为 18 个本征模函数 IMF 分量和一个残差分量 Res。这种分解方式不仅仅体现了 EMD 对信号多尺度结构的灵活适应性，同时也揭示了原始信号在不同时间尺度上的局部特征。每个 IMF 都捕捉了原始信号中特定时间尺度上的振动和波动，而残差分量 Res 则包含了未被这些 IMF 捕捉到的高阶特征。这一丰富而详细的分解结果为本章提供了深入理解传感器数据的新视角。在后续的研究和分析中，本章将利用这些 IMF 分量和残差分量，以更全面、精细的方式探索和挖掘传感器信号中的信息，为进一步的数据建模和应用提供更为丰富的基础。

4.3.4 增量学习实时更新

（1）XGBoost 增量学习模型

在实际应用中，从连续血糖监测系统中获取的血糖仪数据，即血糖数据，呈逐渐增加的趋势。值得注意的是，由于血糖仪中不同批次传感器的差异性，这些新数据通常具有更高的价值。有效处理这些新数据对于提高同批次数据的血糖预测精度具有重要帮助。

随着人工智能和机器学习的不断发展，许多机器学习算法被开发出来。大多数算法采用批处理学习模式，即在训练前一次性获得所有训练样本，在学习过程结束后不再更新。然而，在实际应用中，通常不可能一次获得所有的训练样本，而是随着时间的推移逐渐获得。此外，

中国知网　https://www.cnki.net

样本所反映的信息可能随时间而变化。如果每次有新的样本到达时都需要重新学习所有的数据，将会消耗大量的时间和空间资源，批量学习算法无法满足这一需求。

相对而言，增量学习算法在这种情境下显示出优势。增量学习允许渐进的知识更新，这可以纠正和加强以前的知识，使更新后的模型能够适应新到达的数据，而无需重新学习所有数据。这种学习方法大大减少了对时间和空间资源的需求，更符合实际应用的要求。在血糖预测的场景中，采用增量学习算法能够更好地应对不断涌现的新数据，从而提高模型的准确性和适应性。

为了在实现模型的实时更新的同时提高新数据的血糖预测精度，本节针对第三章训练出的 XGBoost 基模型，采用其两种增量训练方式进行实验。一种是在当前迭代树的基础上增加新树，原树不变；另一种是当前迭代树结构不变，重新计算叶节点权重，同时也可增加新树。

第一种增量训练方式是基于已有的模型结构，根据新数据添加新的树，原理是在底层接口中通过 xgb.train 函数的 xgb_model 参数实现。通过这种方式，新树与已有树共同作用于预测结果。具体步骤实现如下：

（a）通过 save_model 函数保存旧数据训练好的基模型；

（b）将新数据集分为训练集和测试集，并转换为 XGBoost 自己的数据结构 DMatrix，以加快后续的计算；

（c）获取基模型的参数，调用 xgb.train 函数，传入参数、训练集、树的数量（迭代轮数）和基模型的地址；

（d）使用增量训练好的模型对测试集进行预测查看结果。

第二种增量训练方式是在当前迭代树的结构不变的情况下，重新计算叶节点的权重，通过对已有树的叶节点进行修剪和更新来适应新的数据。具体步骤实现如下：

（a）通过 save_model 函数保存旧数据训练好的基模型；

（b）将新数据集分为训练集和测试集，并转换为 XGBoost 自己的数据结构 DMatrix，以加快后续的计算；

（c）设置参数 updater 为 refresh，process_type 为 update，refresh_leaf 为 True；

（d）调用 xgb.train 函数，传入参数、训练集、树的数量（迭代轮数）和基模型的地址；

（e）使用增量训练好的模型对测试集进行预测查看结果。

这两种增量训练方式的实验旨在验证它们对于处理逐渐增加的新数据的效果，并评估对血糖预测精度的提升程度。这样的实时更新策略有助于保持模型的有效性和适应性，使其能够更好地应对不断变化的数据。

（2）LightGBM 增量学习模型

中国知网　https://www.cnki.net

LightGBM 作为 XGBoost 的有力竞争者，其设计之初考虑到了超大数据集的应用，除了提供分布式训练支持外，还专门提供了一种增量训练的方法。相比于 XGBoost，LightGBM 的增量学习方式只有一种，其原理是通过 init_model 和 keep_training_booster 两个参数实现增量训练，具体步骤实现如下：

（a）通过 save_model 函数保存旧数据训练好的基模型；

（b）将新数据集分为训练集和测试集，并转换为 LightGBM 自己的数据结构 Dataset，以加快后续的计算；

（c）获取基模型的参数，调用 xgb.train 函数，传入参数、训练集、树的数量（迭代轮数）和基模型的地址并设置 keep_training_booster 为 True；

（d）使用增量训练好的模型对测试集进行预测查看结果。

这种增量训练方式允许 LightGBM 在已有模型的基础上，通过保留先前的模型状态，继续学习新的数据。这样的实时更新策略有助于提高模型的适应性，使其能够有效地处理逐渐增加的新数据，同时减少了重新训练的时间和计算成本。通过比较 XGBoost 和 LightGBM 的增量训练方式，可以更好地选择适合特定应用场景的模型，并优化血糖预测的性能。

4.4 实验结果及分析

4.4.1 实验环境

本章实验硬件相关配置与 3.4.1 小节中一致：Intel i5-7300 2.5GHz 四核四线程 CPU，16G 内存，Windows10 操作系统，编程语言 Python，编程环境 Pycharm，分别使用了 pywt、PyEMD、pandas、math、xgboost、lightgbm 等库。这些库的综合应用有助于实现实验中所需的各种数据处理、特征提取和机器学习模型的构建与训练。在这样的硬件和软件环境下，本章能够进行有效的实验和深入分析，验证所提出的方法和模型在血糖预测任务中的性能表现。

4.4.2 异常值检测结果分析

为了检测传感器电流信号的异常值，本章采用了箱线图法对数据集进行处理，处理结果如图 4.5 所示。观察图中可以发现，数据集中的异常值主要分布在最大值（约为 15）之后。

针对这些异常值，目前除了删除之外，暂时尚未找到更可靠、更优的处理方法。因此，本章采取了异常值删除的策略，以确保在后续分析和建模过程中能够得到更稳健的结果。对于异常值的删除决策是为了避免其对模型的影响，同时确保模型对正常数据的学习和预测能

中国知网　https://www.cnki.net

够更为准确和可靠。在异常值处理上的谨慎选择有助于提高模型的鲁棒性和可靠性。

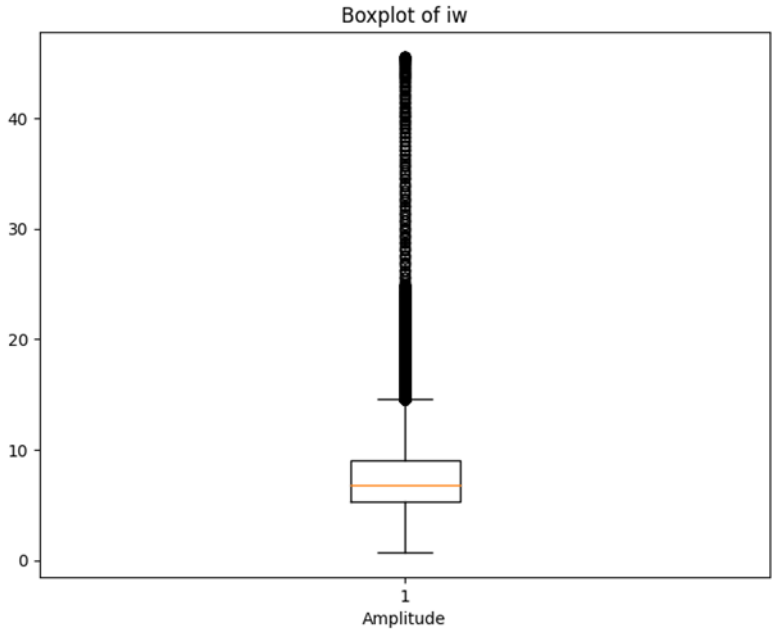

图 4.5 箱线图结果

4.4.3 信号分解结果分析及对比

（1）离散小波变换结果分析

针对分解得到的不同频率分量，有两种处理方式：（a）将这些分量分别输入到 XGBoost 和 LightGBM 模型中进行独立训练。然后，将每个子模型的预测结果进行线性叠加，并取平均，得到最终的血糖预测值。（b）将这些分量作为特征，放入模型中进行训练。最终的血糖预测值即为模型对这些特征的预测结果。

这两种处理方式各有优劣。第一种方式通过独立训练多个模型，充分挖掘了每个频率分量的特征，然后通过线性叠加取平均的方式综合考虑了各个模型的预测结果。这种方式对于不同频率分量之间的相互影响有更灵活的处理，但也增加了模型集成的复杂度。而第二种方式则将不同频率分量作为特征输入到一个模型中进行训练，模型会自动学习各个分量的权重和相互关系。这种方式减少了模型集成的复杂度，但可能在某些情况下无法充分挖掘各个频率分量的特征。

表 4.1 对分量采用不同处理后使用 XGBoost 和 LightGBM 模型预测结果进行了对比。从表中可以观察到，采用第一种分量处理方式并不能降低血糖预测误差，反而有所提高。而采用第二种分量处理方式则明显降低了血糖预测误差。具体来说，在 MAPE 指标上，DWT2-XGBoost 的预测误差比 XGBoost 降低了 0.33%，DWT2-LightGBM 的预测误差比 LightGBM

中国知网 https://www.cnki.net

降低了 0.36%。而在 RMSE 指标上，DWT2-XGBoost 的预测误差比 XGBoost 降低了 0.61mg/dL，DWT2-LightGBM 的预测误差比 LightGBM 降低了 0.43mg/dL。由此可见，离散小波变换在一定程度上能够通过分解信号去除噪声和提取信号的重要特征，从而降低血糖预测误差。采用第二种分量处理方式，将分解得到的频率分量作为特征输入到模型中，更有效地利用了这些特征信息，提高了模型的性能。这一实验结果为在血糖预测中应用离散小波变换提供了有益的参考。

表 4.1 分量处理对比

模型	MAPE(%)	RMSE(mg/dL)
XGBoost	13.85	22.91
LightGBM	14.07	21.54
DWT1-XGBoost	17.81	28.10
DWT1-LightGBM	16.53	25.19
DWT2-XGBoost	13.52	22.30
DWT2-LightGBM	13.71	21.11

（2）经典模态分解结果分析

对于每个 IMF（经验模态分解得到的各个分量），由于它们包含了原信号的不同时间尺度的局部特征信息，我们采用了与对待 DWT 的频率分量相似的两种处理方式：（a）将每个 IMF 分量分别输入到 XGBoost 和 LightGBM 模型中进行独立训练。然后，将每个子模型的预测结果进行线性叠加，并取平均得到最终的血糖预测值。（b）将这些 IMF 分量作为特征，放入模型中进行训练。最终的血糖预测值即为模型对这些特征的预测结果。

这两种处理方式的思路与对待 DWT 的频率分量的处理方式相似，但这里针对 IMF 分量的特定时间尺度局部特征进行处理。这样的处理方式充分考虑了每个 IMF 分量的独特信息，并根据具体任务的需求选择合适的方式。在实验中，可以通过比较这两种处理方式的效果，选择对于血糖预测任务性能更优的方式。

表 4.2 对 IMF 分量采用不同处理方式后使用 XGBoost 和 LightGBM 模型预测结果进行了对比。从表中可以观察到以下情况：（a）采用第一种分量处理方式能稍微降低血糖预测误差。在 MAPE 指标上，EMD1-XGBoost 的预测误差比 XGBoost 降低了 0.01%，EMD1-LightGBM 的预测误差比 LightGBM 降低了 0.46%。然而，在 RMSE 指标上，EMD1-XGBoost 的预测误差比 XGBoost 升高了 0.47mg/dL，EMD1-LightGBM 的预测误差比 LightGBM 降低了 0.54mg/dL。（b）采用第二种分量处理方式则明显降低了血糖预测误差。在 MAPE 指标上，EMD2-XGBoost 的预测误差比 XGBoost 降低了 0.93%，EMD2-LightGBM 的预测误差比 LightGBM 降低了

中国知网 https://www.cnki.net

0.58%。在 RMSE 指标上，EMD2-XGBoost 的预测误差比 XGBoost 降低了 0.85mg/dL，EMD2-LightGBM 的预测误差比 LightGBM 降低了 0.70mg/dL。由此可见，经验模态分解在一定程度上能够通过分解信号提取不同时间尺度的局部特征信息，从而有效降低血糖预测误差。第二种分量处理方式，即将 IMF 分量作为特征输入到模型中训练，表现出更好的性能，为在血糖预测中应用经验模态分解提供了有益的实验结果。

表 4.2 IMF 分量处理对比

模型	MAPE(%)	RMSE(mg/dL)
XGBoost	13.85	22.91
LightGBM	14.07	21.54
EMD1-XGBoost	13.84	23.38
EMD1-LightGBM	13.61	21.00
EMD2-XGBoost	12.92	22.06
EMD2-LightGBM	13.49	20.84

（3）分解算法结果分析及对比

表 4.3 信号分解结果对比

模型	MAPE(%)	RMSE(mg/dL)
XGBoost	13.85	22.91
LightGBM	14.07	21.54
DWT2-XGBoost	13.52	22.30
DWT2-LightGBM	13.71	21.11
EMD2-XGBoost	12.92	22.06
EMD2-LightGBM	13.49	20.84

表 4.3 对采用离散小波变换和经验模态分解后使用 XGBoost 和 LightGBM 模型进行血糖预测的结果进行了对比。从表中可以得出以下结论：（a）采用信号分解算法的实验结果明显优于未做分解的模型。这是因为 DWT 和 EMD 方法通过将非线性的传感器信号分解成近似线性的信号分量，从中提取出信号的重要特征信息，从而减小了血糖预测误差。（b）DWT 和 EMD 在信号分解中的性能表现有所不同。DWT 需要选择小波基函数和分解层级，而小波基函数的选择对整个小波分析的结果有较大影响。与此不同，EMD 具有自适应性，能够有效适应非平稳和非线性信号，因此在对传感器信号处理时，EMD 方法相较于 DWT 表现更为优越。综合而言，信号分解算法在血糖预测中的应用，特别是采用 EMD 方法，能够有效降低预测误差，为血糖预测系统的性能提升提供了有力支持。选择适用的信号分解算法和方法对于任务

中国知网 https://www.cnki.net

的成功实施至关重要。

4.4.4 增量学习结果分析及对比

（1）XGBoost 增量学习结果分析

表 4.4 不同增量训练方式预测结果

模型	MAPE(%)	RMSE(mg/dL)
XGBoost	13.58	23.54
XGB-incremental1	12.73	21.40
XGB-incremental2	13.73	23.47

表 4.4 对采用不同增量学习方式和不使用增量学习（直接使用保存的模型）的预测结果进行了对比。从表中可以得出以下结论：（a）采用第一种增量学习方式能够在降低新数据预测误差的同时实现模型的实时更新。在 MAPE 指标上，XGB-incremental1 的预测误差比 XGBoost 降低了 0.85%；在 RMSE 指标上，XGB-incremental1 的预测误差比 XGBoost 降低了 2.14mg/dL。这说明在采用增量学习的同时，通过在当前迭代树的基础上增加新树，能够更好地适应新数据的规律，降低预测误差。（b）采用第二种增量学习方式并不能够降低新数据的预测误差，未能实现实时更新的同时更好地适应新数据的规律。这可能是因为在当前迭代树的结构不变的情况下，重新计算叶节点的权重并不足以适应新数据的特征，导致模型性能没有明显提升。综合而言，选择合适的增量学习方式对于模型的性能提升至关重要。在本实验中，第一种增量学习方式表现出更好的效果，为实现实时更新和适应新数据提供了可行的方法。

（2）LightGBM 增量学习结果分析

表 4.5 LightGBM 增量学习方式预测结果

模型	MAPE(%)	RMSE(mg/dL)
LightGBM	13.91	21.65
LGB-incremental	12.75	20.73

表 4.5 对 LightGBM 采用增量学习和不采用（直接使用保存的模型）的预测结果进行了对比。从表中可以得出以下结论：采用增量学习方式能够在显著降低新数据预测误差的同时实现模型的实时更新。在 MAPE 指标上，LGB-incremental 的预测误差比 LightGBM 降低了 1.16%；在 RMSE 指标上，LGB-incremental 的预测误差比 LightGBM 降低了 0.92mg/dL。这说明 LightGBM 在增量学习方面表现出色，通过对已有模型的结构进行增量更新，能够更好地适应新数据的规律，提高预测性能。综合而言，采用增量学习方式对于 LightGBM 模型在实

中国知网 https://www.cnki.net

时更新和适应新数据方面带来了显著的性能提升，为模型的应用和维护提供了有效的方法。

（3）增量学习结果分析及对比

表 4.6 对采用合适的 XGBoost 和 LightGBM 增量学习方式与不使用增量学习的预测结果进行了对比。表中前两行是使用训练好的 XGBoost 和 LightGBM 直接预测新数据的测试集的结果，第三行和第四行是使用新数据的训练集重新训练的 XGBoost 和 LightGBM 模型对测试集的预测结果，最后两行是 XGBoost 和 LightGBM 采用增量学习方式后对测试集的预测结果。从表中可以观察到以下情况：（a）相较于使用旧模型和重新训练模型，XGBoost 模型采用增量学习方式后，对血糖的预测效果有一定程度的提升。这表现在 MAPE 和 RMSE 两个指标上，增量学习方式相对于不采用或重新训练表现更好。（b）LightGBM 模型在采用增量学习方式后，对血糖预测的效果有显著提升。MAPE 和 RMSE 两个指标都表现出采用增量学习方式明显优于不采用或重新训练。综合而言，对于 XGBoost 和 LightGBM 模型，采用合适的增量学习方式能够在实时更新模型的同时提高对新数据的预测效果，为模型的应用和维护提供了更为可行的方案。

表 4.6 增量训练方式与不采用结果对比

模型	MAPE(%)	RMSE(mg/dL)
XGBoost	13.58	23.54
LightGBM	13.91	21.65
XGB_new	15.50	26.70
LGB_new	16.08	25.71
XGB-incremental1	12.73	21.40
LGB-incremental	12.75	20.73

图 4.6 展示了各个模型对某患者前 50 条数据的血糖预测结果。从图中可以明显看出，本章提出的基于增量学习的血糖预测实时更新模型的预测结果表现最好，重新训练的预测结果最差，而使用两个基模型的预测结果介于两者之间。结合表 4.6 评价指标来看，XGBoost 增量学习方法的 MAPE 为 12.73、RMSE 为 21.40mg/dL，LightGBM 增量学习方法的 MAPE 为 12.75、RMSE 为 20.73mg/dL，重新训练的 XGBoost 的 MAPE 为 15.50、RMSE 为 26.70mg/dL，重新训练的 LightGBM 的 MAPE 为 16.08、RMSE 为 25.71mg/dL，XGBoost 基模型的 MAPE 为 13.58、RMSE 为 23.54mg/dL，LightGBM 基模型的 MAPE 为 13.91、RMSE 为 21.65mg/dL。本章提出的基于增量学习的血糖预测实时更新模型的 MAPE 和 RMSE 的值最小，表明实时更新模型的预测准确率最高。这与图 4.6 中的预测结果一致，验证了增量学习方法对于提高模型性能的有效性。

中国知网 https://www.cnki.net

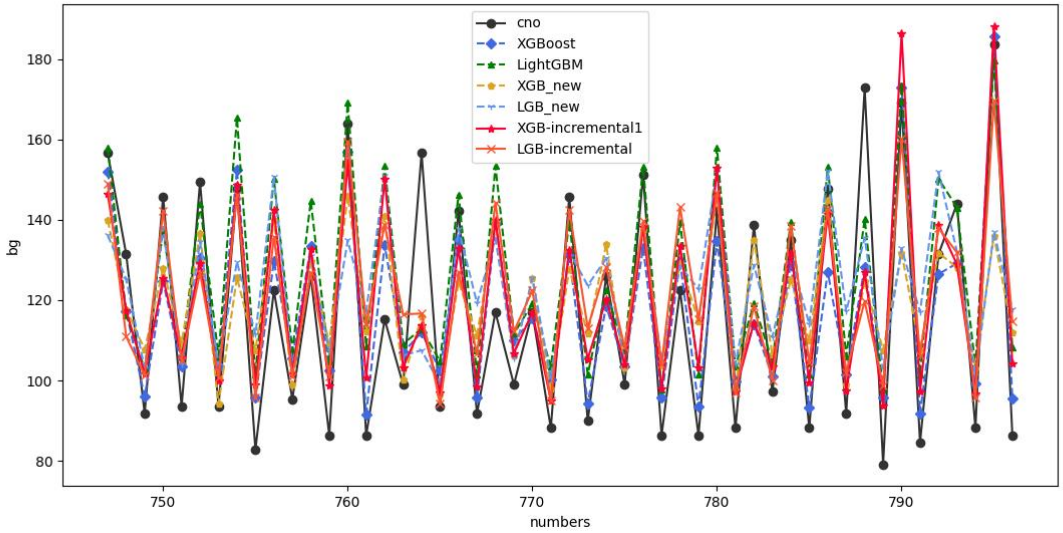

图 4.6 模型预测结果

为了更全面地验证模型的效果，将 XGBoost 增量学习、LightGBM 增量学习、CatBoost、贝叶斯回归(Bayesian regression)、门控循环单元(Gate Recurrent Unit , GRU)、卷积神经网络(Convolutional Neural Networks, CNN)的预测结果进行对比，如表 4.7 所示。通过对比各个模型的预测结果，可以更全面地评估它们在血糖预测任务上的性能。

表 4.7 各个模型预测结果对比

模型	MAPE(%)	RMSE(mg/dL)
CatBoost	13.62	24.10
Bayesian Regression	14.41	23.40
GRU	13.86	25.89
CNN	17.25	28.79
XGB-incremental1	12.73	21.40
LGB-incremental	12.75	20.73

从表 4.7 的结果可以清晰地看出，相较于 CatBoost、贝叶斯回归、GRU、CNN，本章提出的基于增量学习的血糖预测实时更新模型在预测性能上具有明显优势。具体而言，在 MAPE 指标上，XGBoost 增量学习的预测效果比 CatBoost 提高了 0.89%，LightGBM 增量学习的预测效果比 CatBoost 提高了 0.87%。而在 RMSE 指标上，XGBoost 增量学习的预测效果比 CatBoost 提高了 2.70mg/dL，LightGBM 增量学习的预测效果比 CatBoost 提高了 3.37mg/dL。

综合来看，从这两个指标的提升幅度来看，本章提出的基于增量学习的血糖预测实时更新模型在预测效果和泛化能力上均显著优于 CatBoost、贝叶斯回归、GRU、CNN。这表明增

中国知网 https://www.cnki.net

量学习方法在处理逐步增加的血糖仪数据上具有更好的适应性和性能，为实际应用中的血糖预测提供了可行的解决方案。

通过图 4.7 可以清晰地观察到 CatBoost、贝叶斯回归、GRU、CNN 和实时更新模型对某患者血糖值的预测结果。由图 4.7 可知，本章提出的基于增量学习的实时更新模型展现了最佳的预测效果，其次是 CatBoost 模型，而 CNN 模型的预测效果最差。GRU 和贝叶斯回归模型的预测效果介于这些模型之间。综合考虑表 4.7 的评价指标，CatBoost 模型的 MAPE 为 13.62、RMSE 为 24.10mg/dL，CNN 模型的 MAPE 为 17.25、RMSE 为 28.79mg/dL，GRU 模型的 MAPE 为 13.86、RMSE 为 25.89mg/dL，贝叶斯回归模型的 MAPE 为 14.41、RMSE 为 23.40mg/dL，而实时更新模型的 MAPE 为 12.73%和 12.75%，RMSE 为 21.40mg/dL 和 20.73mg/dL，相较于其他模型具有更高的准确性和更好的泛化性能。与图 4.7 的观察结果一致，这说明了实时更新模型在血糖预测方面具有良好的效果。

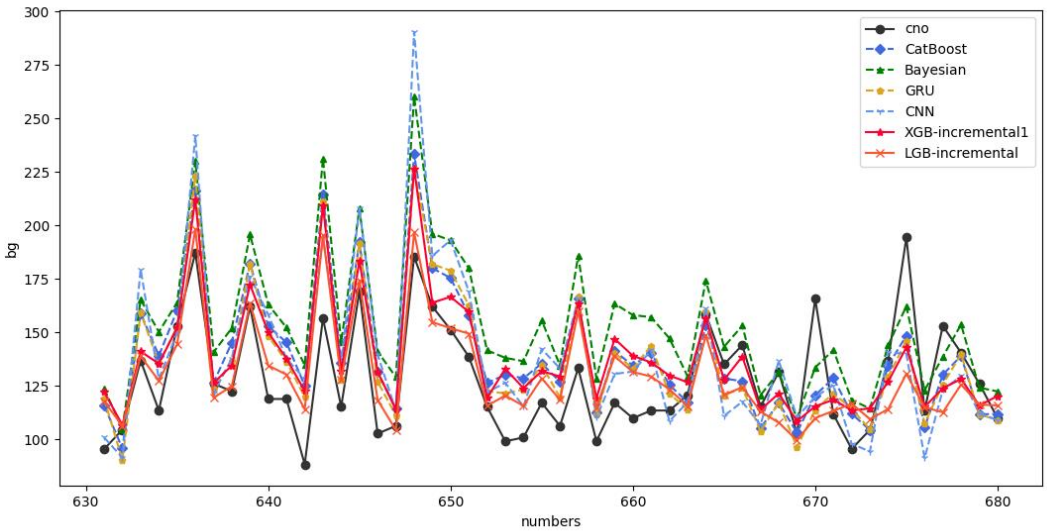

图 4.7 不同模型预测结果

综合图 4.6 和图 4.7，它们展示了各个模型在测试集中某患者前 50 条血糖数据的预测结果与真实值的对比。观察图中的结果，与使用旧模型、重新训练模型、CatBoost、贝叶斯回归、GRU、CNN 相比，基于增量学习的血糖预测实时更新模型在大多数情况下都呈现出与真实血糖值非常接近的预测结果，表现出更高的拟合程度。这说明该模型能够在减少模型训练时间的同时，对新数据进行学习，实现预测误差的降低。综上所述，本章提出的基于增量学习的血糖预测实时更新模型在血糖预测方面具有一定的优越性。

在表 4.8 中列举了不同模型的训练时间消耗，并指出 XGBoost 增量学习和 LightGBM 增量学习的时间消耗是基模型的训练时间和增量学习训练时间之和的总时间消耗。观察表格，可以看出贝叶斯回归模型的时间消耗最短，XGBoost 增量学习和 LightGBM 增量学习次之，

中国知网 https://www.cnki.net

而 GRU 和 CNN 的时间消耗最长。然而，通过对比表 4.7 中的预测结果不难看出，尽管贝叶斯回归模型训练时间较短，但其预测效果远不及基于增量学习的实时更新模型。因此，无论从预测结果还是从训练时间消耗的角度来看，本章提出的基于增量学习的血糖预测实时更新模型都表现出最优的性能，再次证明了该模型的优越性。

表 4.8 不同模型训练时间消耗对比

模型组合	时间（s）
CatBoost	18.336
Bayesian Regression	0.275
GRU	859.592
CNN	1175.456
XGB-incremental1	7.780
LGB-incremental	0.469

4.5 本章小结

本章提出的基于增量学习的血糖预测实时更新模型采用了一系列方法来提高对传感器信号的血糖值预测精度。首先，通过箱线图法进行异常值检测，对卡尔曼滤波后的数据进行处理，以提高数据质量。然后，采用离散小波变换和经验模态分解对传感器信号进行分解，比较两者的效果，选择性能更优的方法。最后，利用 XGBoost 和 LightGBM 两种增量学习方式对模型进行新数据的训练和测试，实现在减少模型训练时间的同时，对新数据的血糖值进行更为准确的预测。在实验对比中，基于增量学习的血糖预测实时更新模型相较于基模型和重新训练的模型，表现出更高的预测精度。在预测误差上，相较于两个基模型有 0.85%和 1.16%的降低，并且相较于重新训练的模型和其他模型，也具有更高的预测精度。这表明增量学习的方式在提高模型效果的同时，显著降低了训练时间，使得模型能够更及时地适应新数据的规律，从而实现对血糖值的更准确预测。综合实验结果，基于增量学习的血糖预测实时更新模型在血糖值预测方面表现出明显的优越性。

中国知网　https://www.cnki.net

第五章 基于机器学习的血糖预测系统

糖尿病作为一种慢性病，其患者数量不断增加，迫切需要更有效的血糖管理手段。在这一背景下，血糖预测显得尤为重要。通过对个体的血糖水平进行预测，可以实现更个性化的治疗方案，提高治疗效果。本章是建立在第三章和第四章的基础之上，设计与实现一个基于机器学习的血糖预测系统。

5.1 设计背景

随着糖尿病治疗研究不断深入，人们开始关注血糖监测技术的发展。最初的方法是通过采集患者血液样本并进行化学分析，但这既痛苦又不方便。科学家们为此着手研发非侵入式的血糖监测技术。近年来，随着生物传感器、无线通信和计算机技术的不断进步，血糖监测技术取得了巨大突破。现在，人们可以选择使用无创的设备，如穿戴式传感器和连续血糖监测仪，便捷地检测和监控血糖水平。这些设备不仅方便患者使用，还能提供实时准确的血糖数据，有助于患者和医生更有效地管理糖尿病。同时，这些新型监测设备通过无线通信技术，能够将患者的血糖数据实时传输至云端或医疗系统，为医生提供了更及时、精准的患者状况分析。这样的实时监测和数据共享不仅加强了医患之间的沟通，也为治疗方案的调整提供了更科学的依据。

基于血糖仪数据和第三章、第四章的算法模型，本章设计与实现一个基于机器学习的血糖预测系统。该系统采用 MongoDB+TDengine 双数据源来存储用户信息和所佩戴的血糖仪数据，并使用当下流行的 Vue3 和 SpringCloud Alibaba 实现前后端分离开发。基于本系统，管理者可以实时观察用户信息和所佩戴的血糖仪数据变化，也可以更加直观地统计到不同类型血糖仪的数据统计，另外基于第三章和第四章提出的预测模型，管理者能够实时观察不同模型的预测效果，对于日后的数据处理以及模型的选择从而实现降低血糖误差有着一定的作用。

5.2 技术概述

5.2.1 MongoDB 数据库

MongoDB[51-53]是一个非关系型数据库，采用了文档存储模型，以及 JavaScript 作为查询语言。它使用集合(Collection)来存储数据，集合由文档组成。MongoDB 的主要优点是具有灵

中国知网 https://www.cnki.net

活的数据模型，可以存储各种类型的数据，同时具有高度的可伸缩性和高可用性。另外，MongoDB 支持多种索引，如单字段索引、复合索引等，可以提高查询性能。

MongoDB 是一种非结构化数据库，不仅能够处理结构化数据，而且更适合处理非结构化数据，如文本、图像和超媒体信息。它克服了关系型数据库的结构定义和数据长度的限制，具有处理连续信息和非结构化信息的优势，这是关系型数据库无法比拟的。MongoDB 的优势在于高性能处理大数据量、易扩展、高可用性，能够轻松实现大数据存储需求。此外，它具有完善的 Java API、以 JSON 格式存储数据，便于 Java 和 JavaScript 处理，运维方面也相对便捷，具备清晰的版本控制和活跃的社区支持。

5.2.2 TDengine 时序数据库

TDengine 是一款开源、云原生的时序数据库，专为物联网、工业互联网、金融、IT 运维监控等场景而设计和优化[54-56]。它能够高效实时地处理大量设备和数据采集器每天产生的 TB 甚至 PB 级数据，实时监测和预警业务运行状态，并从大数据中挖掘出商业价值。它能够充分利用时序数据的特点，通过创新的存储引擎设计，无论是数据写入还是查询，TDengine 时序数据库的性能比通用数据库快 10 倍以上，也远超其他时序数据库，存储空间不及通用数据库的 1/10。

5.2.3 Vue 前端

Vue 是一款用于构建用户界面的 JavaScript 框架[57-59]。它基于标准 HTML、CSS 和 JavaScript 构建，并提供了一套声明式的、组件化的编程模型，帮助开发者高效地开发用户界面。Vue3 是 Vue 的最新版本，它在 Vue2 的基础上进行了更新升级，并且引入了 composition API 等新特性。

composition API 的引入使 Vue3 更加适应大型应用的开发，使得组织和重用代码更为容易。此外，Vue3 还改进了性能，优化了底层的响应式系统，提升了整体性能表现。这对于构建高效的用户界面至关重要，尤其是在复杂的应用场景下。

另外，Vue3 依然保留了 Vue2 的所有写法，采用了兼容性的设计，使得迁移和升级过程更加平滑。这一特性对于已经在使用 Vue2 的开发者而言尤为重要，可以在不破坏原有代码的基础上享受 Vue3 的新特性。

中国知网 https://www.cnki.net

5.2.4 SpringCloud 框架

SpringCloud 作为 Spring 家族的一部分，受益于 Spring 在 JavaEE 开发领域的卓越地位，为 SpringCloud 的推广提供了有力支持。同时，SpringCloud 基于的 SpringBoot 已经成为 JavaEE 领域最受欢迎的开发框架之一，用于简化 Spring 应用程序的搭建和开发过程。这一整合使得 SpringCloud 成为构建分布式系统的理想选择，充分发挥了 Spring 家族在 Java 开发中的广泛应用和强大生态系统的优势[60-62]。

其次，技术组件的完备性是开发人员选择 SpringCloud 的主要原因。SpringCloud 集成了一个完整的微服务系统开发所需的技术组件，包括服务注册与发现、API 网关、配置中心、消息处理、负载均衡、熔断器以及数据监控等。这些常见技术组件都能够快速地基于 SpringBoot 集成到业务系统中。

SpringCloud Alibaba 是一站式的微服务开发解决方案，结合了阿里巴巴丰富的微服务实践经验。作为 SpringCloud 的第二代实现的主要组成部分，它使开发人员能够轻松地将 SpringCloud 应用接入到阿里微服务解决方案中。通过添加少量注解和配置，依托 SpringCloud Alibaba，开发人员能够迅速搭建分布式应用系统，利用阿里中间件实现高效的微服务架构。

5.3 系统设计

5.3.1 数据库设计

（1）MongoDB 数据库设计

本文的数据集是基于某公司血糖仪数据，其中包含用户的个人信息、所穿戴的设备信息、传感器信号信息以及穿戴信息。

用户信息（HIS）：包括用户 ID、姓名、性别、年龄、身高、体重、用户所患糖尿病类型等基本信息。

设备信息（二维码）：包括数据来源、设备 ID、设备名称、设备类型、设备所在位置、设备状态等信息。

传感器信号信息（信号描述）：包括时间、工作电流、空白电流、温度、设备内置算法预测的血糖值等信息。

穿戴信息（穿戴描述）：包括起始时间、结束时间、算法 K/R 值、算法版本等信息。

用户姓名、性别、年龄、身高、体重、糖尿病类型是基本的、相对稳定的信息，适合存储

中国知网 https://www.cnki.net

在一个独立的嵌套集合中，以方便用户信息的集中管理和查询。设备 ID、设备名称、设备类型、所在位置、状态、数据来源等信息相对独立且与多个用户相关，因此适合存储在单独的嵌套集合中，以避免数据冗余并提高设备信息的可维护性。传感器信号数据量大且变化频繁，包含时间、工作电流、空白电流、温度、预测的血糖值等动态数据，适合单独存储，并通过用户 ID 和设备 ID 关联，确保数据的灵活性和查询效率。起始时间、结束时间、算法 K/R 值、算法版本等信息与设备的使用情况相关，适合单独存储并与用户和设备进行关联，以便于跟踪设备的使用情况和算法的版本控制。

另外在数据库架构设计阶段，创建适当的集合和嵌套文档结构，使得数据存储高效且易于扩展。同时，设计合理的索引（如用户 ID、设备 ID、时间戳等字段）以提高查询性能。例如，为用户集合中的用户 ID 字段创建索引，便于快速检索用户数据；为血糖信息集合中的用户 ID 和时间戳字段创建索引，以优化时间序列数据的查询效率。

基于这些信息，本文设计以下 MongoDB 嵌套类型数据库：

集合 cgm_login 即账户信息的数据项如表 5.1 所示：

表 5.1 账户信息

字段名	字段类型	备注
_id	STRING	主键
username	STRING	用户名
password	STRING	密码

集合 cgm_info 即用户完整 cgm 信息的数据项如表 5.2 所示：

表 5.2 完整 cgm 信息

字段名	字段类型	备注
_id	STRING	主键
user_id	STRING	用户 id
did	STRING	设备 id
dataset	STRING	数据集
init_time	STRING	初始化时间
end_time	STRING	结束时间
type	STRING	sn 类型
emitter_sn	STRING	具体 sn 号
utel	STRING	手机号码
header		数据头

中国知网 https://www.cnki.net

duration	INT32	持续时间
event_num	INT32	异常数量
cno_num	INT32	cno 数量
uinfo		用户信息
user_name	STRING	用户姓名
user_type	INT32	用户类型
gender	INT32	性别
age	INT32	年龄
height	INT32	身高
weight	INT32	体重
sick_duration	INT32	患者持续时间
dinfo		设备信息
data_source	INT32	数据来源
wear_position	STRING	穿戴位置
create_time	STRING	创建时间
sensor_id	STRING	传感器 id
transmitter_sn	STRING	发射器 sn 号
R	DOUBLE	R 值
K	DOUBLE	K 值
sensor_info	STRING	传感器信息
sensor_batch	STRING	传感器批次
left_padding	DOUBLE	左侧留白
right_padding	DOUBLE	右侧留白
elect_width	DOUBLE	电池宽度
elect_length	DOUBLE	电池长度
enzyme	INT32	酶
thickness	INT32	浓度
signaures		信号信息
time	STRING	时间
iw	DOUBLE	工作电流

中国知网 https://www.cnki.net

ib	DOUBLE	空白电流
t	DOUBLE	温度
glu	DOUBLE	血糖值
record		佩戴信息
init_time	STRING	初始化时间
end_time	STRING	结束时间
algorithm_k	DOUBLE	算法 K 值
algorithm_r	DOUBLE	算法 R 值
algorithm_version	STRING	算法版本

（2）TDengine 时序数据库设计

基于用户血糖数据，本文设计以下 TDengine 时序数据库：

超级表 **cgm_blood_glucose_value** 即连续波形时序数据库表如表 5.3 所示。

表 5.3 不同增量训练方式预测结果

字段名	字段类型	备注
ts	TIMESTAMP	时间戳
record_id	INT	记录 ID
work_electricity	FLOAT	工作电流
temperature	FLOAT	温度
calibration_value	FLOAT	校准值
calibration_mg_value	FLOAT	校准 mg
calibration_count	INT	校准计数
calibration_subtract_count	INT	校准细分计数
trend	INT	趋势
error_code	INT	错误代码
glucose_data	FLOAT	葡萄糖数据
glucose_mg_data	FLOAT	葡萄糖 mg 数据
calibration_status	INT	校准状态
TAGS		标签
id	BINARY	ID
user_uid	BINARY	用户 ID

中国知网 https://www.cnki.net

algorithm_version	BINARY	算法版本

5.3.2 框架设计

微服务架构作为一种先进的解决方案，需要选择适当的技术框架来实现。全球范围内的互联网公司都在积极探索和尝试各自的微服务落地技术。在国内，最知名的微服务框架包括SpringCloud 和阿里巴巴的 Dubbo。

SpringCloud 是国内应用最广泛的微服务框架之一，集成了各种微服务功能组件，并利用SpringBoot 实现了这些组件的自动装配，为开发人员提供了便捷的开箱即用体验。SpringCloud的设计理念是通过提供一整套解决方案，简化微服务架构的开发和部署，从而加速应用的上线和迭代。

近年来，SpringCloud Alibaba 逐渐崭露头角，吸收了 SpringCloud Netflix 的核心架构思想并进行了高性能改进。随着 SpringCloud Netflix 进入停更维护，SpringCloud Alibaba 逐渐取代它成为主流的微服务框架。该框架在保留 SpringCloud 的优势的基础上，更好地满足了高性能和稳定性的需求。

基于这些微服务框架的特性，系统后端进行了相应的设计，如表 5.4 所示。通过选择 Spring Cloud Alibaba 作为微服务的技术框架，系统可以充分利用其丰富的功能组件和高性能的特点，为用户提供稳定、高效的服务。未来的发展方向可能包括进一步优化微服务架构、提升系统的可扩展性以及跟踪新兴技术的发展，以确保系统始终保持在技术前沿。

表 5.4 框架设计

配置	技术栈
服务注册中心	Nacos
服务配置中心	Nacos
服务远程调用	Feign
服务网关	Gateway
服务接口	Restful API

Nacos：是一种分布式服务发现和配置管理工具，它可以用于服务注册、健康检查、负载均衡、故障恢复、动态配置等方面。Nacos 支持多种服务发现方式和多种协议，可以帮助开发人员和运维人员更好地管理和维护分布式系统。

Feign：是一个声明式的 HTTP 客户端，使得开发人员能够便捷、优雅地发送 HTTP 请求。它简化了微服务之间的调用过程，类似于控制器调用服务。在 SpringCloud 中，使用 Feign 时

中国知网 https://www.cnki.net

还可以提供负载均衡的 HTTP 客户端功能。

Gateway：gateway 网关服务是一种用于管理网络流量的工具。它可以帮助企业实现数据的安全传输和流量的控制管理。gateway 网关服务的主要功能包括网络流量管理、数据过滤、安全检测、流量控制、应用加速等。

RESTful 接口：RESTful 接口使用标准的 HTTP 方法（GET、POST、PUT、DELETE 等）和 URL 来进行通信，使接口设计简单且易于理解。另外它是一种无状态的架构，客户端和服务器之间的交互不依赖于会话状态。这使得系统更容易扩展，添加新功能或修改现有功能而无需对整体架构进行大规模更改。

本文前端采用 Web 前端架构，使用 element ui plus 组件进行开发，基于 Vue 框架实现功能展示。主界面与界面详情分离，通过封装后端通信请求实现前后端联动，从而完善整个系统功能。首页头部(MyHeader)、侧边栏(Sidebar)，以及详情页(AppMain)三个组件相结合，通过 index.vue 的目录形式将各模块有条理地分隔开。通过 router 路由中间件实现了每个模块的直接跳转。利用 Promise 中的 axios 方法发送 get 或 post 请求，用户可以通过请求反馈不同的展示功能，如用户信息管理、数据统计以及模型实时预测。

5.3.3 功能概述

本系统将第三章和第四章的血糖预测模型算法成功应用，涉及前后端开发、机器学习、数据分析等多种技术领域。系统整体功能分为三个主要模块，分别是血糖数据统计模块、用户信息管理模块，以及用户血糖预测模块。系统设计如图 5.1 所示，其中每个模块都在系统中扮演着关键的角色。

血糖数据统计模块负责收集、整理和统计用户的血糖数据，具体功能包括记录每个血糖仪产品含真实血糖值的人数，以及各类产品的分布情况。管理者可以通过该模块进行统计图的下载，图中包含产品名称、总数以及百分比信息，使得数据更加直观。通过鼠标悬停，管理员可以方便地查看详细信息。此外，该模块还会记录各类产品的佩戴数据总数以及七天内新增数据数量，这些新增数据以折线图的形式展现在每日数据统计图中，为管理者提供更全面的数据分析。

用户信息管理模块则主要用于记录用户的基础信息，包括姓名、手机号码等个人信息。同时，该模块还记录用户穿戴设备的使用情况，包括初始化成功时间、发射器 SN 号、佩戴天数以及真实血糖值(cno)点数等。管理员可以在该模块进行用户基础信息的查看、编辑和删除操作，实现对用户信息的灵活管理。此外，管理员还可以批量导出指定用户的信息成 CSV 文

中国知网 https://www.cnki.net

件，方便数据的整理和备份。

用户血糖预测模块在系统中扮演着关键角色，其主要任务是记录用户佩戴血糖仪的总体数据，包括工作电流信号、空白电流信号、温度，以及每日的指尖采血值。此外，该模块内嵌了第三章和第四章的算法模型，能够以每三分钟一次的频率对用户血糖值进行精准预测。同时该模块提供实时更新开关功能，开启后后台会实时监测产品的用户数量，当数量达到 3 时，会对模型进行实时更新。

为了方便管理员的数据查看和分析，该模块提供了多种信息交互的能力。首先，通过鼠标悬停显示数据，管理员可以轻松获取不同时间点的详细信息，包括工作电流值、空白电流值、温度等，同时还能查看每日各个时间点的指尖采血值、stacking 模型融合预测值、XGBoost 增量学习预测值以及 LightGBM 增量学习预测值。

其次，管理员可以使用鼠标滚轮对折线图进行放大或缩小，以便更为细致地查看数据。这种交互方式使得管理员能够灵活地调整视图，从而更清晰地观察血糖趋势和变化。

另外，模块还提供了拖动条细查数据的功能，管理员可以通过拉动每日血糖折线图下方的拖动条，对折线图进行放大或缩小，以更详细地查看指定时间范围内的数据。同时点击图例可以使折线图显示和隐藏。这些交互方式的引入，使管理员能够以直观、灵活的方式查看用户的血糖数据，包括实时数据和预测值。这不仅提高了系统的实用性，也为管理员提供了更为强大的数据分析工具，有助于更全面地了解和管理用户的血糖情况。

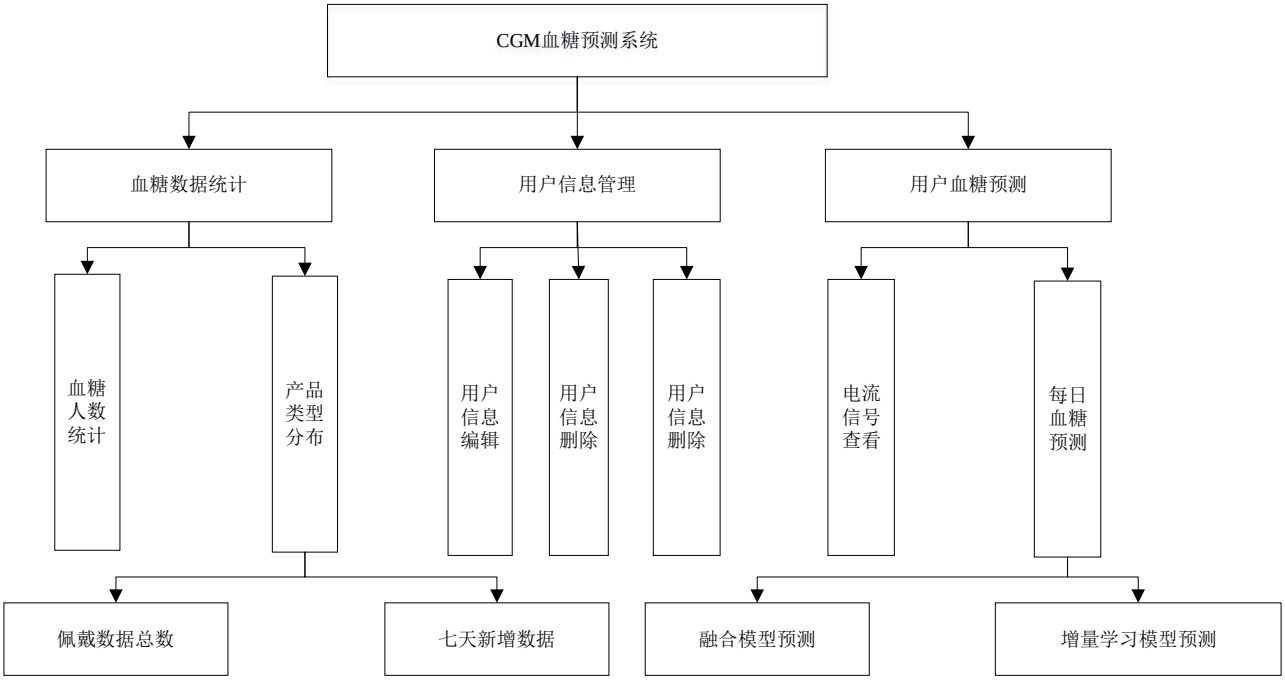

图 5.1 系统实现设计图

中国知网 https://www.cnki.net

5.4 系统实现

5.4.1 初始登录界面

系统的初始界面呈现为一个登录页面，具体设计如图 5.2 所示。该页面旨在提供管理员登录与注册功能。在管理员尝试登录时，系统会验证输入的账号和密码，如果服务器中没有相关账号或密码错误，则会显示登录失败的提示信息，要求重新输入正确的账号和密码。

这登录页面的设计旨在确保系统的安全性和合法访问。管理员通过正确的账号和密码登录系统，以获取对系统功能和数据的访问权限。对于错误的登录尝试，系统会及时反馈失败信息，促使管理员采取正确的措施，如重新输入正确的登录信息或进行账号注册。整体而言，登录页面是系统的入口，通过有效的身份验证机制，确保只有授权的管理员能够进入系统，从而保障系统的安全性和可控性。

图 5.2 系统登录界面

5.4.2 数据统计界面

管理员登录成功后，将进入系统的首页，设计如图 5.3 所示。该首页主要展示了每种血糖仪产品所含真实血糖值的数量，以及各类型产品的分布图。每张图的左下角提供了下载功能，管理员可以通过点击按钮将饼图保存到本地图片。通过鼠标悬停在图表上，管理员还可以方便地查看产品的名称、总数以及百分比等详细信息。

这样的首页设计使管理员能够迅速了解系统中各类血糖仪产品的分布情况，以及它们所含真实血糖值的数量。通过直观的图表展示，管理员可以在一张页面上获取重要的数据概览，

中国知网 https://www.cnki.net

提高了信息呈现的效率。下载功能的提供也为管理员提供了保存和分享数据的便捷途径。总体而言，首页的设计旨在为管理员提供直观、易于理解的数据可视化，使其能够迅速了解系统的整体情况，为后续的管理和决策提供有力支持。

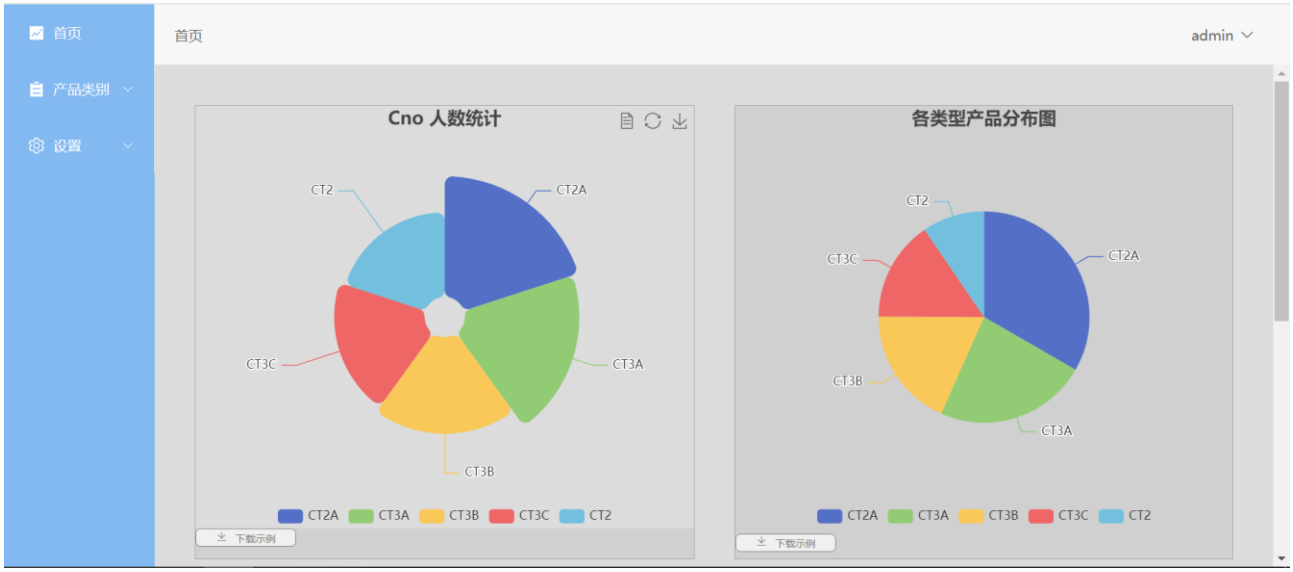

图 5.3 系统首页

通过点击侧边栏，管理员可以查看每种产品具体的一些数据统计，系统界面设计如图 5.4 所示。这个界面详细展示了各类产品的佩戴数据总数以及七天内新增数据数量。这些新增数据以折线图的方式清晰地展现在每日数据统计图中。

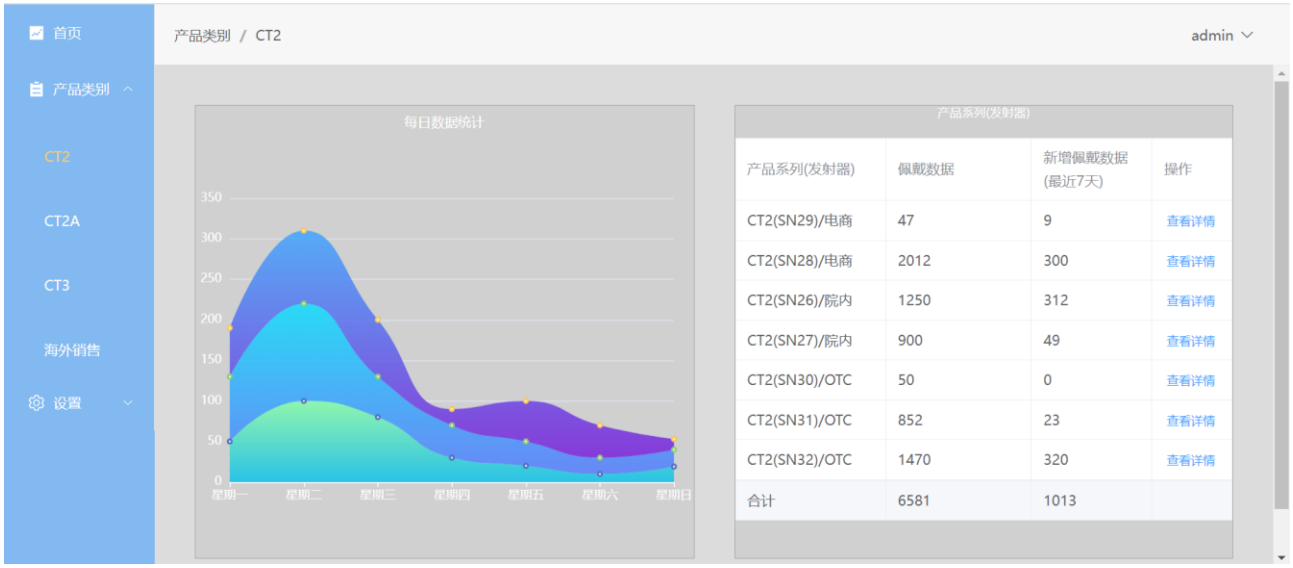

图 5.4 各类产品数据统计

在这个界面中，管理员能够快速了解每种产品的佩戴情况，包括总体的佩戴数据和近期的新增数据趋势。通过折线图的形式，管理员可以直观地观察数据的变化趋势，有助于及时发现潜在的问题或趋势。这样的数据统计界面提供了更为详细和个性化的产品数据信息，为管理员提供了更全面的数据分析工具。通过图表展示，管理员能够更深入地了解各种产品的使用情况，为决策和管理提供更有针对性的支持。这样的设计有助于管理员更有效地监控和

中国知网 https://www.cnki.net

管理系统中各种血糖仪产品的运行状况。

5.4.3 用户信息管理界面

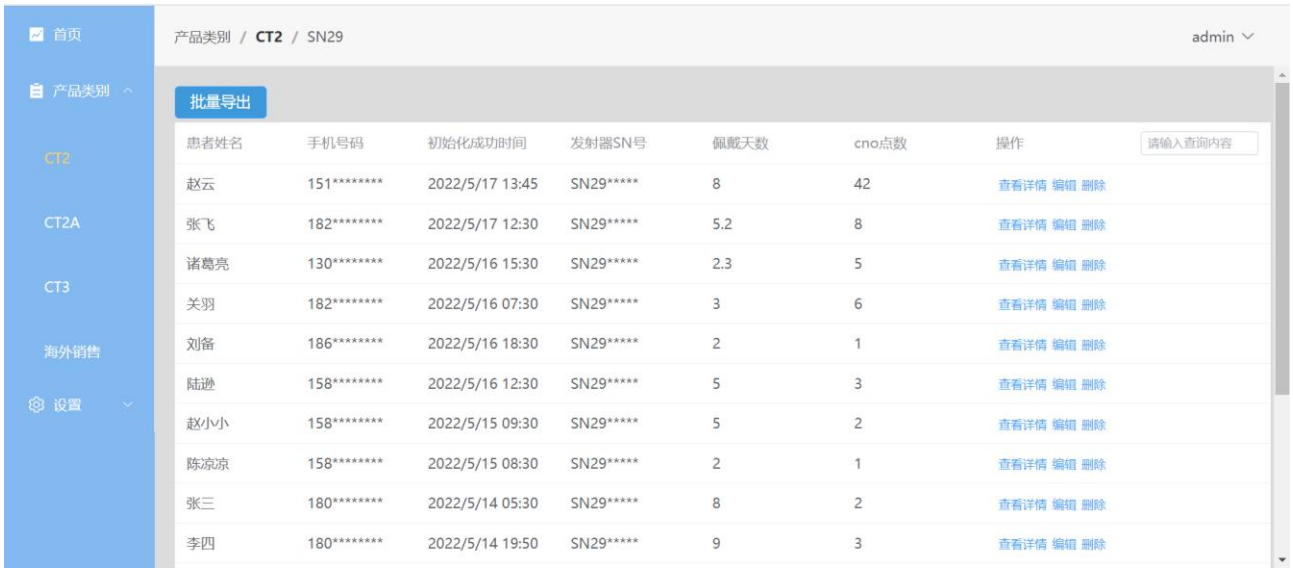

图 5.5 用户信息管理

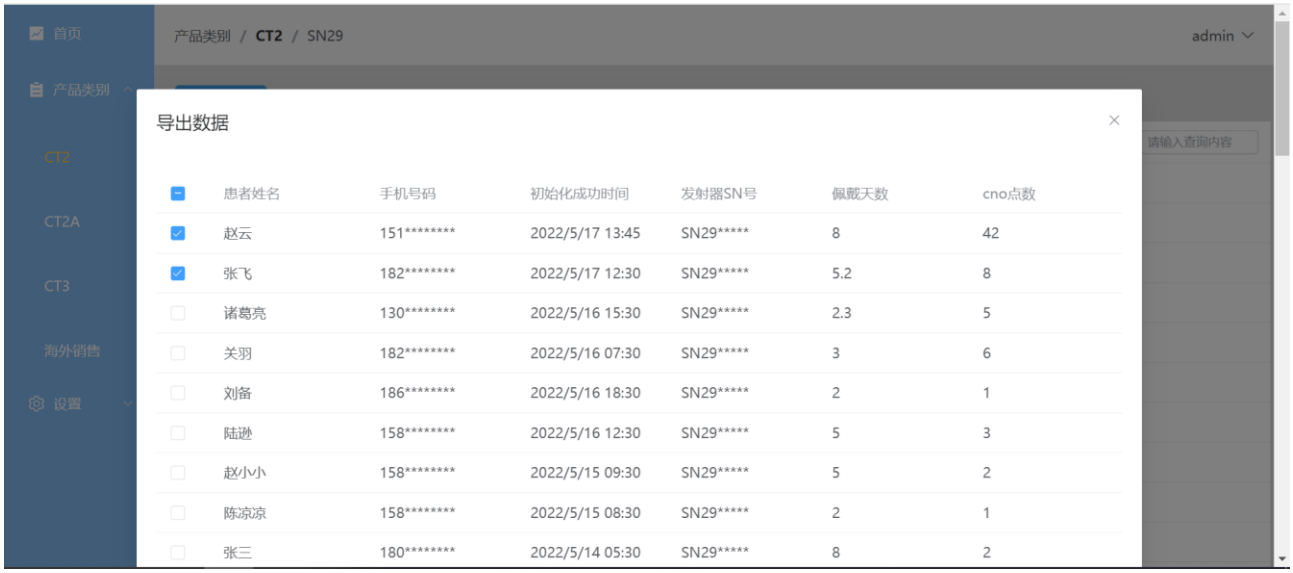

图 5.6 批量导出数据

当管理员在数据统计界面点击查看详情后，将进入用户信息管理界面，其设计如图 5.5 所示。这个界面主要用于记录用户的基础信息，包括姓名、手机号码等个人信息，同时也详细记录了用户穿戴设备的使用情况，包括初始化成功时间、发射器 SN 号、佩戴天数以及真实血糖值(cno)点数等。在用户信息管理界面，管理员拥有多项操作权限，包括：（1）查看：管理员可以查看用户的基础信息和穿戴设备使用情况，了解用户的整体情况；（2）编辑：管理员可以对用户的基础信息进行编辑，以确保数据的准确性和及时性；（3）删除：管理员可以删除不再需要的用户信息，保持数据库的整洁和精简；（4）批量导出：管理员可以选择批量导

中国知网 https://www.cnki.net

出指定用户的信息成 CSV 文件，方便数据的整理和备份。图 5.6 展示了批量导出的界面，管理员可以通过简单的操作实现对用户信息的大规模导出。这样的用户信息管理界面为管理员提供了便捷而全面的用户信息管理工具，使其能够高效地维护和管理用户数据库。通过这些功能，系统支持管理员在数据管理方面更灵活、更高效地运营。

5.4.4 血糖预测界面

管理员在用户信息管理界面点击查看详情后，将进入血糖预测界面，该界面分为两个主要部分：

第一个部分是用户佩戴传感器所有时间的工作电流值、空白电流值以及温度和实时更新开关如图 5.7 所示。在这个部分，管理员可以通过鼠标悬停查看某个时间点的三类值。通过鼠标滚轮，管理员能够方便地放大或缩小指定时间范围内的折线图，以便更为细致地查看数据。这种交互方式使得管理员能够直观地观察传感器各项数据的趋势和变化。另外点击实时更新开关，开启后后台会实时监测产品的用户数量，当数量达到 3 时，会对模型进行实时更新。

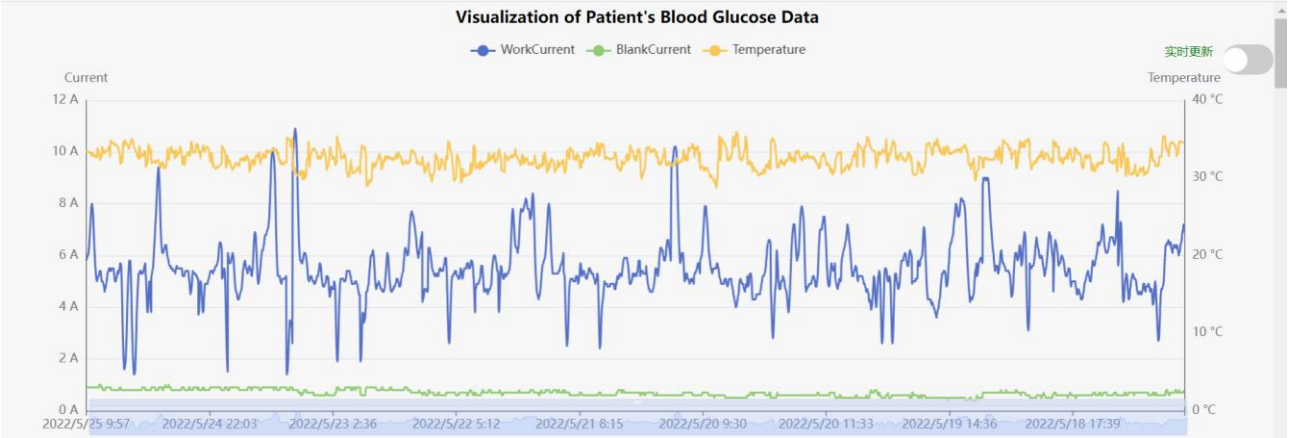

图 5.7 传感器电流及温度和实时更新开关

第二部分是每日对用户血糖值进行每三分钟一次的预测，如图 5.8、图 5.9 所示。在这个部分，管理员可以通过鼠标悬停查看某个时间点的指尖采血值(Fingertip)、stacking 模型融合预测值、XGBoost 增量学习预测值以及 LightGBM 增量学习预测值。同样，通过鼠标滚轮和下方拖动条，管理员可以放大或缩小指定时间范围内的折线图，以便更为细致地查看数据。这种交互方式使管理员能够全面了解每日血糖值的预测情况。

这两个部分的设计使得管理员可以通过直观的图表和交互方式，深入了解用户的生理数据和血糖值预测情况。这有助于管理员更全面地了解用户的健康状况，为个性化的健康管理提供了科学依据。

中国知网 https://www.cnki.net

图 5.8 2022 年 5 月 25 日血糖值预测

图 5.9 2022 年 5 月 24 日血糖值预测

5.5 本章小结

本章实现了第三章和第四章提出的基于粒子群优化和模型融合的血糖预测模型，以及基于增量学习的血糖预测实时更新模型。同时，设计并实现了一个完整的基于机器学习的 CGM 血糖预测系统。该系统采用模块化设计，包括血糖数据统计模块、用户信息管理模块和用户血糖预测模块。在该系统中，管理员可以实时观察用户信息和所佩戴的血糖仪数据的变化。通过模块化设计，系统提供了直观的用户界面，使得管理员可以更加便捷地统计不同类型血糖仪的数据情况。另外，基于第三章和第四章提出的预测模型，管理员能够实时观察不同模型的预测效果。系统的优势在于管理员可以直观地监测和统计用户的血糖数据，实时观察各种血糖仪的数据变化趋势，并对不同预测模型的效果进行比较。这为日后的数据处理和模型的选择提供了科学依据，有助于降低血糖预测误差，提高系统的可用性和精准性。总体而言，该系统不仅实现了血糖预测模型，还通过模块化设计提供了全面的监测和管理功能，使得管理员能够更好地了解用户的健康状况，为个性化的健康管理提供了技术支持。

中国知网 https://www.cnki.net

第六章 总结与展望

6.1 研究总结

随着科技的不断进步，连续血糖监测系统所提供的大量医疗数据成为糖尿病管理中的重要资源。利用机器学习算法分析这些数据，可以帮助医生更准确地预测患者的血糖水平变化趋势。通过深入挖掘 CGMS 记录的血糖数据以及患者的生理特征和生活习惯等信息，机器学习模型可以建立起个体化的血糖预测模型，为患者提供更精准的健康管理建议，帮助他们更好地控制血糖水平，改善生活质量。

基于某公司 CGMS 提供的血糖数据，本文选择机器学习中的集成学习和增量学习为理论基础，提出一种基于机器学习的血糖预测算法，该方法先是通过粒子群优化算法对 XGBoost 模型、LightGBM 模型进行超参数寻优，并通过 stacking 模型融合的思想将优化后的模型进行融合，使用融合后的模型对血糖值进行预测，后为应对不断增长的新数据，通过信号分解算法和增量学习方法实现模型的实时更新，每当新增数据时，并不需要重新训练模型，而是在原有的知识库的基础上，仅根据新增数据所引起的变化对模型实时更新。最后，基于上述模型，设计与实现了一种基于机器学习的血糖预测系统。本文具体工作如下：

（1）本文提出的基于模型融合的血糖预测模型采用了一系列有效的处理步骤，通过卡尔曼滤波算法和 z-score 方法对传感器数据进行预处理，再利用粒子群优化算法对 XGBoost 和 LightGBM 模型进行超参数优化。最后，以优化后的 XGBoost 和 LightGBM 模型为基学习器，结合贝叶斯回归模型作为元学习器，对传感器数据进行训练和测试，实现对血糖值的较为准确的预测。通过实验对比的结果显示，本文提出的血糖预测模型在预测效果上明显优于单一的基学习器，取得了 1.76%和 2.07%的预测精度提升。相较于其他回归模型和不同的组合模型，该融合模型也展现出更高的预测精度。

（2）本文提出的基于增量学习的血糖预测实时更新模型采用了一系列方法来提高对传感器信号的血糖值预测精度。首先，通过箱线图法进行异常值检测，对卡尔曼滤波后的数据进行处理，以提高数据质量。然后，采用离散小波变换和经验模态分解对传感器信号进行分解，比较两者的效果，选择性能更优的方法。最后，利用 XGBoost 和 LightGBM 两种增量学习方式对模型进行新数据的训练和测试，实现在减少模型训练时间的同时，对新数据的血糖值进行更为准确的预测。在实验对比中，基于增量学习的血糖预测实时更新模型相较于基模型和重新训练的模型，表现出更高的预测精度。在预测误差上，相较于两个基模型有 0.85%和 1.16%

中国知网 https://www.cnki.net

的降低，并且相较于重新训练的模型和其他模型，也具有更高的预测精度。

（3）本文实现了第三章和第四章提出的基于模型融合的血糖预测模型，以及基于增量学习的血糖预测实时更新模型。同时，设计并实现了一个完整的基于机器学习的 CGM 血糖预测系统。该系统采用模块化设计，包括血糖数据统计模块、用户信息管理模块和用户血糖预测模块。在该系统中，管理员可以实时观察用户信息和所佩戴的血糖仪数据的变化。通过模块化设计，系统提供了直观的用户界面，使得管理员可以更加便捷地统计不同类型血糖仪的数据情况。另外，基于第三章和第四章提出的预测模型，管理员能够实时观察不同模型的预测效果。系统的优势在于管理员可以直观地监测和统计用户的血糖数据，实时观察各种血糖仪的数据变化趋势，并对不同预测模型的效果进行比较。这为日后的数据处理和模型的选择提供了科学依据，有助于降低血糖预测误差，提高系统的可用性和精准性。

6.2 研究展望

虽然本文在血糖值预测研究中取得了一些进展，但对于模型精度的提高和模型的改进，还有一些不足的地方，因此本文对未来的展望如下：

（1）本文是通过人工选择最佳的模型组合，而不是通过智能化的组合机制，故其效率不高。希望在后期的研究中，能够建立基学习器库，结合不同的群智能优化算法，实现基学习器的自动组合，以达到最优的预测效果。

（2）在传感器信号采集过程中，可能会受到外界因素的干扰，如传感器脱出、胶布松动、防水失效、外膜破损等情况，这些因素可能导致数据采集异常。然而，许多机器学习算法在存在异常值的情况下表现不佳，因此需要引入异常检测技术以应对这种情况。本文直接选择的是箱线图法，没有对其深入的研究从而选择更合适的算法。另外，对于异常值的处理，本文是直接采用的是删除策略。因此，异常检测和处理也是未来的研究方向之一。

（3）本文采用的是 XGBoost 模型和 LightGBM 模型的增量学习方法，未来可以考虑其他算法模型的增量学习方法与之对比，设计更合适的实时更新模型，并深入研究增量学习策略对系统性能的影响。

中国知网 https://www.cnki.net

参考文献

[1] 郭赛金. 糖尿病患者护理中的饮食营养研究——评《糖尿病饮食四宜五忌》[J]. 食品安全质量检测学报, 2022, 13(2): 679-680.

[2] 王誉霖. 基于群智能优化算法和XGBoost的血糖预测模型研究[D]. 北京化工大学, 2021.

[3] Wang Y, Zhang H, An Y, et al. RG Hyperparameter Optimization Approach for Improved Indirect Prediction of Blood Glucose Levels by Boosting Ensemble Learning[J]. Electronics, 2021, 10(15): 1797-1820.

[4] Obeidat Y, Ammar A. A System for Blood Glucose Monitoring and Smart Insulin Prediction[J]. IEEE Sensors Journal, 2021, 21(12): 13895-13909.

[5] Iacono F, Magni L, Toffanin C. Personalized LSTM Models for Glucose Prediction in Type 1 Diabetes Subjects[C]. 30th Mediterranean Conference on Control and Automation (MED), 2022: 324-329.

[6] Jaloli M, Cescon M. Long-Term Prediction of Blood Glucose Levels in Type 1 Diabetes Using A CNN-LSTM-Based Deep Neural Network[J]. Journal of Diabetes Science and Technology, 2023, 17(6): 1590-1601.

[7] van der Linden J, Welsh J B, Walker T C. Sustainable Use of A Real-Time Continuous Glucose Monitoring System from 2018 to 2020[J]. Diabetes Technology and Therapeutics, 2021, 23(7): 508-511.

[8] Freckmann G. Basics and Use of Continuous Glucose Monitoring (CGM) in Diabetes Therapy[J]. Journal of Laboratory Medicine, 2020, 44(2): 71-79.

[9] 罗淑芳, 张威鹏, 潘莹. 连续血糖监测系统对比分析[J]. 中国医疗器械信息, 2021, 27(9): 8-9.

[10] Reifman J, Rajaraman S, Gribok A, et al. Predictive Monitoring for Improved Management of Glucose Levels[J]. Journal of Diabetes Science and Technology, 2007, 1(4): 478-486.

[11] Gani A, Gribok A V, Rajaraman S, et al. Predicting Subcutaneous Glucose Concentration in Humans: Data-Driven Glucose Modeling[J]. IEEE Transactions on Biomedical Engineering, 2008, 56(2): 246-254.

[12] Gani A, Gribok A V, Lu Y, et al. Universal Glucose Models for Predicting Subcutaneous Glucose Concentration in Humans[J]. IEEE Transactions on Information Technology in Biomedicine, 2009, 14(1): 157-165.

[13] Wang Z, Lai L, Xiong D, et al. Study on Predicting Method for Acute Hypotensive Episodes Based on Wavelet Transform and Support Vector Machine[C]. 3rd International Conference on Biomedical Engineering and Informatics, 2010: 1041-1045.

[14] Huang S, Cai N, Pacheco P P, et al. Applications of Support Vector Machine (SVM) Learning in Cancer Genomics[J]. Cancer Genomics and Proteomics, 2018, 15(1): 41-51.

[15] Asad M, Qamar U, Zeb B, et al. Blood Glucose Level Prediction with Minimal Inputs Using Feedforward Neural Network for Diabetic Type 1 Patients[C]. Proceedings of The 2019 11th International Conference on Machine Learning and Computing, 2019: 182-185.

[16] Aliberti A, Pupillo I, Terna S, et al. A Multi-Patient Data-Driven Approach to Blood Glucose Prediction[J]. IEEE Access, 2019, 7(7): 69311-69325.

[17] Hamdi T, Ali J B, Di Costanzo V, et al. Accurate Prediction of Continuous Blood Glucose Based on Support Vector Regression and Differential Evolution Algorithm[J]. Biocybernetics and Biomedical Engineering, 2018, 38(2): 362-372.

[18] Ali J B, Hamdi T, Fnaiech N, et al. Continuous Blood Glucose Level Prediction of Type 1 Diabetes Based on Artificial Neural Network[J]. Biocybernetics and Biomedical Engineering, 2018, 38(4): 828-840.

[19] Dong Y, Wen R, Li Z, et al. Clu-RNN: A New RNN Based Approach to Diabetic Blood Glucose Prediction[C]. 7th International Conference on Bioinformatics and Computational Biology (ICBCB), 2019: 50-55.

[20] Alfian G, Syafrudin M, Rhee J, et al. Blood Glucose Prediction Model for Type 1 Diabetes Based on Extreme Gradient Boosting[C]. IOP Conference Series: Materials Science and Engineering, 2020: 12012-12020.

中国知网 https://www.cnki.net

[21] Wang Y, Wang T. Application of Improved LightGBM Model in Blood Glucose Prediction[J]. Applied Sciences, 2020, 10(9): 3227-3243.
[22] 滕建丽, 容芷君, 许莹, 等. 基于GRU网络的血糖预测方法研究[J]. 计算机应用与软件, 2020, 37(10): 107-112.
[23] 童梦, 丁国荣, 余楠, 等. 一种基于VMD-PSO-LSTM的血糖预测方法[J]. 计算机与数字工程, 2023, 51(6): 1439-1443.
[24] 胡蓉. 增量机器学习算法研究[D]. 南京理工大学, 2013.
[25] He J, Mao R, Shao Z, et al. Incremental Learning in Online Scenario[C]. Proceedings of The IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 13926-13935.
[26] 陈晋音, 陈治清, 郑海斌, 等. 基于PSO的路牌识别模型黑盒对抗攻击方法[J]. 软件学报, 2020, 31(9): 2785-2801.
[27] 李建伟, 刘成波, 郭宏, 等. 基于PSO-RBF神经网络的刀具寿命预测[J]. 计算机系统应用, 2022, 31(1): 309-314.
[28] Bi J, Zhao M, Yao G, et al. PSOSVRPos: WiFi Indoor Positioning Using SVR Optimized by PSO[J]. Expert Systems with Applications, 2023, 222(13): 119778-119789.
[29] Asselman A, Khaldi M, Aammou S. Enhancing The Prediction of Student Performance Based on The Machine Learning XGBoost Algorithm[J]. Interactive Learning Environments, 2023, 31(6): 3360-3379.
[30] Wang Y, Jiang W. Application of XGBoost Model in The Field of Diabetes Prediction[J]. Advances in Computer, Signals and Systems, 2023, 7(8): 29-36.
[31] 王晓晖, 张亮, 李俊清, 等. 基于遗传算法与随机森林的XGBoost改进方法研究[J]. 计算机科学, 2020, 47(S2): 454-458.
[32] Cao Q, Wu Y, Yang J, et al. Greenhouse Temperature Prediction Based on Time-Series Features and LightGBM[J]. Applied Sciences, 2023, 13(3): 1610-1631.
[33] Su Y, Jiang X. Prediction of Tide Level Based on Variable Weight Combination of LightGBM and CNN-BiGRU Model[J]. Scientific Reports, 2023, 13(1): 9-22.
[34] 孙全明, 曲志坚, 任崇广. 基于粒子群优化和LightGBM的情景感知多式联运推荐[J]. 电子学报, 2021, 49(5): 894-903.
[35] Li M, Yan C, Liu W. The Network Loan Risk Prediction Model Based on Convolutional Neural Network and Stacking Fusion Model[J]. Applied Soft Computing, 2021, 113(10): 107961-107973.
[36] 杨望, 高明哲, 蒋婷. 一种基于多特征集成学习的恶意代码静态检测框架[J]. 计算机研究与发展, 2021, 58(5): 1021-1034.
[37] 梁荣华, 谢晓兰, 翟青海, 等. 基于改进的Stacking集成模型的容器云负载预测研究[J]. 计算机应用与软件, 2023, 40(12): 48-55.
[38] Wang M, Lu S, Liao R. Fault Diagnosis for Power Cables Based on Convolutional Neural Network with Chaotic System and Discrete Wavelet Transform[J]. IEEE Transactions on Power Delivery, 2021, 37(1): 582-590.
[39] 刘凤, 曾文锋, 张文天, 等. 基于频域解离特征的OCT指纹表征攻击检测[J]. 计算机学报, 2024, 47(2): 323-336.
[40] Li H, Lv Z, Li J, et al. Traffic Flow Forecasting in The COVID-19: A Deep Spatial-Temporal Model Based on Discrete Wavelet Transformation[J]. ACM Transactions on Knowledge Discovery from Data, 2023, 17(5): 1-28.
[41] 田佳, 王德勇, 师文喜. 基于集合经验模态分解和随机森林的短时交通流预测[J]. 科学技术与工程, 2023, 23(29): 12612-12619.
[42] 孔繁苗, 高鹭, 李鹏程, 等. EMD-LSTM-LB分频时序预测算法[J]. 计算机工程与设计, 2023, 44(10): 3021-3030.
[43] Guo R, Wang Y, Zhang H, et al. Remaining Useful Life Prediction for Rolling Bearings Using EMD-RISI-

中国知网 https://www.cnki.net

LSTM[J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70(6): 1-12.

[44] Abedinia O, Lotfi M, Bagheri M, et al. Improved EMD-Based Complex Prediction Model for Wind Power Forecasting[J]. IEEE Transactions on Sustainable Energy, 2020, 11(4): 2790-2802.

[45] Revach G, Shlezinger N, Van Sloun R J, et al. Kalmannet: Data-Driven Kalman Filtering[C]. IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2021: 3905-3909.

[46] Feng S, Li X, Zhang S, et al. A Review: State Estimation Based on Hybrid Models of Kalman Filter and Neural Network[J]. Systems Science and Control Engineering, 2023, 11(1): 2173682-2173695.

[47] 徐恩松，陆文华，刘云飞，等. 基于卡尔曼滤波的数据融合算法与应用研究[J]. 计算机技术与发展, 2020, 30(5): 143-147.

[48] Henderi H, Wahyuningsih T, Rahwanto E. Comparison of Min-Max Normalization and Z-Score Normalization in The K-nearest Neighbor (KNN) Algorithm to Test The Accuracy of Types of Breast Cancer[J]. International Journal of Informatics and Information Systems, 2021, 4(1): 13-20.

[49] Wang X, Wang X, Han L. A Novel Parallel Architecture for Template Matching Based on Zero-Mean Normalized Cross-Correlation[J]. IEEE Access, 2019, 7(12): 186626-186636.

[50] Majaw N, Ahmed S S. Exploring Data Distributions Using Box and Whisker Plot Analysis[C]. 14th International Conference on Computing Communication and Networking Technologies (ICCCNT), 2023: 1-8.

[51] Győrödi C A, Dumşe-Burescu D V, Zmaranda D R, et al. A Comparative Study of MongoDB and Document-Based MySQL for Big Data Application Data Management[J]. Big Data and Cognitive Computing, 2022, 6(2): 49-68.

[52] Medina J M, Blanco I J, Pons O. A Fuzzy Database Engine for MongoDB[J]. International Journal of Intelligent Systems, 2022, 37(9): 5691-5724.

[53] Erraji A, Maizate A, Ouzzif M. An Integral Approach for Complete Migration from A Relational Database to MongoDB[J]. Journal of the Nigerian Society of Physical Sciences, 2023, 5(4): 1089-1112.

[54] Gavrikova S V. Time Series Databases Overview[J]. International Journal of Open Information Technologies, 2023, 11(11): 83-102.

[55] Han L, Hu L, Jia S. Experimental Research on TSN Network Performance Test Based on Real-Time Edge Computing Platform[C]. Third International Conference on Computer Science and Communication Technology (ICCSCT 2022), 2022: 678-684.

[56] Parvizi M, Noei M, Yalpanian M. Highly Scalable Smart Metering IoT Platform Based on Microservice Architecture[C]. Sixth International Conference on Smart Cities, Internet of Things and Applications (SCIoT), 2022: 1-6.

[57] Bielak K, Borek B, Plechawska-Wójcik M. Web Application Performance Analysis Using Angular, React and Vue. Js Frameworks[J]. Journal of Computer Sciences Institute, 2022, 23(12): 77-83.

[58] Irhansyah T, Nasution M I P. Development of Thesis Repository Application in The Faculty of Science and Technology Use Implementation of Vue. Js Framework[J]. Journal of Information Systems and Technology Research, 2023, 2(2): 66-77.

[59] Vyas R. Comparative Analysis on Front-End Frameworks for Web Applications[J]. International Journal for Research in Applied Science and Engineering Technology, 2022, 10(7): 298-307.

[60] Kozak M. Analysis of The Spring Boot and Spring Cloud in Developing Java Cloud Applications[J]. Journal of Computer Sciences Institute, 2023, 27(10): 112-120.

[61] Quiña-Mera A, Flores Landeta D, Rea-Peñafiel X M, et al. Quality Evaluation of A Spring Cloud Microservices Architecture Implementation[C]. Communication, Smart Technologies and Innovation for Society: Proceedings of CITIS 2021, 2022: 745-754.

[62] Sun H, Cui T, Niu H, et al. Environmental Sanitation Operation Vehicle Supervision System Based on SpringCloud Microservices[C]. 11th Joint International Information Technology and Artificial Intelligence

中国知网 https://www.cnki.net

Conference (ITAIC), 2023: 781-785.

中国知网 https://www.cnki.net